



# Instituto Politécnico Nacional

CENTRO DE INVESTIGACIÓN E INNOVACIÓN  
TECNOLÓGICA

**“Sistema de apoyo para la detección de fibromas  
uterinos en imágenes de ultrasonido empleando  
redes neuronales convolucionales”**

## TESIS

para obtener el grado de:

**Maestro en Tecnología Avanzada**

PRESENTA:

**ING. OWEN DANIEL MENDOZA REYNA**

DIRECTORES DE TESIS:

Dr. Viridiana Hernández Herrera  
Esp. Karen Eunice Hernández Allende



CIUDAD DE MÉXICO, MÉXICO

01 DE JULIO DE 2025



# INSTITUTO POLITÉCNICO NACIONAL

## SECRETARÍA DE INVESTIGACIÓN Y POSGRADO

SIP-13  
REP 2017

### ACTA DE REGISTRO DE TEMA DE TESIS Y DESIGNACIÓN DE DIRECTOR DE TESIS

Ciudad de México a **6** de **junio** de 2025

El Colegio de Profesores de Posgrado de **Centro de Investigación e Innovación Tecnológica (CIITEC)** en su Sesión

(Unidad Académica)

**Ordinaria** No. **5** celebrada el día **27** del mes **mayo** de **2025** conoció la solicitud presentada por el (la) alumno (a):

Apellido Paterno:	MENDOZA	Apellido Materno:	REYNA	Nombre (s):	OWEN DANIEL
-------------------	---------	-------------------	-------	-------------	-------------

Número de registro:

**B 2 3 1 1 9 1**

del Programa Académico de Posgrado: **Maestría en Tecnología Avanzada**

Referente al registro de su tema de tesis; acordando lo siguiente:

1.- Se designa al aspirante el tema de tesis titulado:

Sistema de apoyo para la detección de fibromas uterinos en imágenes de ultrasonido empleando Redes Neuronales Convolucionales

Objetivo general del trabajo de tesis:

Desarrollar un sistema inteligente basado en redes neuronales convolucionales para la detección y segmentación automática de fibromas uterinos en imágenes de ultrasonido

2.- Se designa como Directores de Tesis a los profesores:

Director: **Dra. Viridiana Gudelia Hernández Herrera** 2° Director: **Esp. Karen Eunice Hernández Allende**  
No aplica: ☐

3.- El Trabajo de investigación base para el desarrollo de la tesis será elaborado por el alumno en:

Centro de Investigación e Innovación Tecnológica

que cuenta con los recursos e infraestructura necesarios.

4.- El interesado deberá asistir a los seminarios desarrollados en el área de adscripción del trabajo desde la fecha en que se suscribe la presente, hasta la aprobación de la versión completa de la tesis por parte de la Comisión Revisora correspondiente.

Director(a) de Tesis

Dra. Viridiana Gudelia Hernández Herrera

Aspirante

Owen Daniel Mendoza Reyna

2° Director de Tesis (en su caso)

Esp. Karen Eunice Hernández Allende

Presidente del Colegio

SECRETARÍA DE EDUCACIÓN PÚBLICA  
INSTITUTO POLITÉCNICO NACIONAL

Dr. Ricardo Rafael Ambroz Rojas

CENTRO DE INVESTIGACIÓN E  
INNOVACIÓN TECNOLÓGICA  
DIRECCIÓN



# INSTITUTO POLITÉCNICO NACIONAL

## SECRETARÍA DE INVESTIGACIÓN Y POSGRADO

SIP-14  
REP 2017

### ACTA DE REVISIÓN DE TESIS

En la Ciudad de **México** siendo las **12** horas del día **01** del mes de **Julio**  
del **2025** se reunieron los miembros de la Comisión Revisora de la Tesis, designada por el Colegio de Profesores de  
Posgrado de: **Centro de Investigación e Innovación Tecnológica (CIITEC)** la tesis titulada:

**Sistema de apoyo para la detección de fibromas uterinos en imágenes de ultrasonido empleando Redes Neuronales Convolucionales**

del (la) alumno (a):

Apellido Paterno:	<b>MENDOZA</b>	Apellido Materno:	<b>REYNA</b>	Nombre (s):	<b>OWEN DANIEL</b>
-------------------	----------------	-------------------	--------------	-------------	--------------------

Número de registro:

**B 2 3 1 1 9 1**

Aspirante del Programa Académico de Posgrado:

**MAESTRÍA EN TECNOLOGÍA AVANZADA**

Una vez que se realizó un análisis de similitud de texto, utilizando el software antiplagio, se encontró que el trabajo de tesis tiene **3** % de similitud. **Se adjunta reporte de software utilizado.**

Después que esta Comisión revisó exhaustivamente el contenido, estructura, intención y ubicación de los textos de la tesis identificados como coincidentes con otros documentos, concluyó que en el presente trabajo SI ☐ NO ☒  
**SE CONSTITUYE UN POSIBLE PLAGIO.**

#### JUSTIFICACIÓN DE LA CONCLUSIÓN:

Debido a que el porcentaje de similitud corresponde a citas textuales que fueron debidamente referenciadas o a trabajos científicos previos realizados por el mismo laboratorio.

**\*\*Es responsabilidad del alumno como autor de la tesis la verificación antiplagio, y del Director o Directores de tesis el análisis del % de similitud para establecer el riesgo o la existencia de un posible plagio.**

Finalmente, y posterior a la lectura, revisión individual, así como el análisis e intercambio de opiniones, los miembros de la Comisión manifestaron APROBAR ☒ SUSPENDER ☐ NO APROBAR ☐ la tesis por

UNANIMIDAD ☒ o MAYORÍA ☐ en virtud de los motivos siguientes:

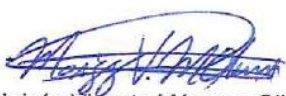
Cumple con los requisitos señalados en el reglamento de posgrado del Instituto Politécnico Nacional

#### COMISIÓN REVISORA DE TESIS

  
Dra. Viridiana Gudelia Hernández  
Herrera  
Directora de Tesis  
Nombre completo y firma

  
Esp. Karen Eunice Hernández Allende  
2do. Directora de Tesis  
Nombre completo y firma

  
Dra. Claudia Azola Cortés Escobedo  
Nombre completo y firma

  
Dr. Moisés Vicente Márquez Olivera  
Nombre completo y firma

  
M. en T.A. Octavio Sánchez García  
Nombre completo y firma

  
SECRETARÍA DE EDUCACIÓN PÚBLICA  
INSTITUTO POLITÉCNICO NACIONAL  
CENTRO DE INVESTIGACIÓN E  
INNOVACIÓN TECNOLÓGICA  
Dr. Ricardo Rafael Ambríz Rojas  
Nombre completo y firma  
PRESIDENTE DEL COLEGIO DE  
PROFESORES





## INSTITUTO POLITÉCNICO NACIONAL

### SECRETARÍA DE INVESTIGACIÓN Y POSGRADO

#### CARTA DE AUTORIZACIÓN DE USO DE OBRA PARA DIFUSIÓN

En la Ciudad de México el día 30 del mes de Junio del año 2025, el (la) que suscribe Owen Daniel Mendoza Reyna alumno(a) del programa Maestría en Tecnología Avanzada con número de registro B231191, adscrito(a) a Centro de Investigación e Innovación Tecnológica (CIITEC) manifiesta que es autor(a) intelectual del presente trabajo de tesis bajo la dirección de la Dra. Viridiana Gudelia Hernández Herrera y la Esp. Karen Eunice Hernández Allende y cede los derechos del trabajo intitulado "Sistema de apoyo para la detección de fibromas uterinos en imágenes de ultrasonido empleando redes neuronales convolucionales", al Instituto Politécnico Nacional, para su difusión con fines académicos y de investigación.

Los usuarios de la información no deben reproducir el contenido textual, gráficas o datos del trabajo sin el permiso expresado del autor y/o director(es). Este puede ser obtenido escribiendo a las siguiente(s) dirección(es) de correo omendozar1500@alumno.ipn.mx. Si el permiso se otorga, al usuario deberá dar agradecimiento correspondiente y citar la fuente de este.

Owen Daniel Mendoza Reyna



**INSTITUTO POLITÉCNICO NACIONAL**  
**SECRETARÍA DE INVESTIGACIÓN Y POSGRADO**

Ciudad de México, 30 de junio de 2025

**Asunto**

**Participación en la dirección de tesis**

**Owen Daniel Mendoza Reyna**

H. COLEGIO DE PROFESORES DE CIITEC  
CIITEC – Instituto Politécnico Nacional

Por medio del presente, describo a Ustedes mi participación como director del presente trabajo de investigación que lleva por título "Sistema de apoyo para la detección de fibromas uterinos en imágenes de ultrasonido empleando Redes Neuronales Convolucionales" del alumno de Maestría en Tecnología Avanzada Owen Daniel Mendoza Reyna, con número de boleta B231191 adscrito al Centro de Investigación e Innovación Tecnológica.

1. Propuesta del tema de tesis sobre detección de fibromas uterinos.
2. Revisión crítica del documento de tesis, con especial atención a planteamiento del problema.
3. Dirección académica y metodológica del proyecto de tesis durante su desarrollo.
4. Elaboración de observaciones detalladas para mejora de la expresión oral y defensa del proyecto de tesis.
5. Asistencia en el diseño e implementación de la experimentación
6. Enseñanza especializada en el área de aprendizaje profundo.
7. Elaboración de observaciones y sugerencias para mejora en la redacción, argumentación y presentación del documento final.
8. Revisión y corrección de tesis.

---

Dra. Viridiana G. Hernández Herrera  
Director de tesis



**INSTITUTO POLITÉCNICO NACIONAL**  
**SECRETARÍA DE INVESTIGACIÓN Y POSGRADO**

Ciudad de México, 30 de junio de 2025

**Asunto**

**Participación en la dirección de tesis**

**Owen Daniel Mendoza Reyna**

H. COLEGIO DE PROFESORES DE CIITEC  
CIITEC – Instituto Politécnico Nacional

Por medio del presente, describo a Ustedes mi participación como director del presente trabajo de investigación que lleva por título " Sistema de apoyo para la detección de fibromas uterinos en imágenes de ultrasonido empleando Redes Neuronales Convolucionales " del alumno de Maestría en Tecnología Avanzada Rodrigo Alejandro Higareda Campos, con número de boleta B231191 adscrito al Centro de Investigación e Innovación Tecnológica.

1. Apoyo en la formulación y delimitación del tema de tesis.
2. Revisión crítica del documento de tesis, con especial atención en la resolución del problema.
3. Desarrollo experimental y análisis de resultados.
4. Provisión de datos variados para experimentación.
5. Validación clínica de los datos experimentales.
6. Evaluación del cumplimiento de los objetivos planteados en el protocolo de investigación.
7. Elaboración de observaciones y sugerencias para mejorar la redacción, argumentación y presentación del documento final.
8. Revisión y corrección de tesis.

---

Esp. Karen Eunice Hernández Allende  
Director de tesis

# Resumen

Los fibromas uterinos son tumores benignos comunes en mujeres principalmente en edad reproductiva, afectando su calidad de vida y, en algunos casos, su fertilidad. La detección precisa y temprana de fibromas mediante ultrasonido es crucial para el tratamiento adecuado, pero la interpretación de estas imágenes puede ser subjetiva y dependiente de la experiencia del médico entre otros factores que derivan en variabilidad de la precisión interpretación. Este proyecto tiene como objetivo desarrollar un sistema de apoyo basado en redes neuronales convolucionales (CNN) para asistir la detección de fibromas uterinos en imágenes de ultrasonido. Se recopilará una base de datos de imágenes de ultrasonido de úteros con y sin fibromas, provenientes de fuentes nacionales, que serán etiquetadas con la asistencia de expertos. Utilizando técnicas de procesamiento de imágenes, se diseñará un algoritmo de aprendizaje profundo y se entrenará una CNN para identificar fibromas. Los resultados preliminares han mostrado una precisión variable según el conjunto de datos, en la detección de fibromas, indicando un alto potencial del sistema propuesto para asistir a los médicos en el diagnóstico. Este avance podría mejorar significativamente la precisión y rapidez en la detección de fibromas uterinos, facilitando intervenciones médicas oportunas y efectivas

# Abstract

Uterine fibroids are common benign tumors in women, primarily during reproductive age, affecting their quality of life and, in some cases, fertility. Accurate and early detection of fibroids through ultrasound is crucial for appropriate treatment, yet the interpretation of these images can be subjective and dependent on the physician's experience, among other factors, leading to variability in diagnostic accuracy. This project aims to develop a support system based on Convolutional Neural Networks (CNNs) to assist in the detection of uterine fibroids in ultrasound images. A database of ultrasound images of uterus with and without fibroids will be collected from national sources and labeled with expert assistance. Using image processing techniques, a deep learning algorithm will be designed, and a CNN will be trained to identify fibroids. Preliminary results have shown variable accuracy depending on the dataset, indicating strong potential for the proposed system to support physicians in diagnosis. This advancement could significantly improve the accuracy and speed of fibroid detection, facilitating timely and effective medical interventions.



# Agradecimientos

Este trabajo fue posible gracias a la beca otorgada por CONAHCyT por lo que se extiende un amplio agradecimiento.

Al Instituto Politécnico Nacional, que ah sido mi segunda casa desde la adolescencia y me ah permitido formarme como profesionista mediante las personas e infraestructura que lo conforman.

A la Secretaria de Investigación y Posgrado por el recurso otorgado para el desarrollo del proyecto.

A la Medico Karen E.H.A. por su colaboración, aportes y constante entusiasmo.

A la Dra. Viridiana por incentivar mi desarrollo y brindarme las oportunidades.

Al Dr. Moisés por su disponibilidad, confianza y presión que ayudaron en todo momento.

A la Dra. Laura por el reconocimiento, consejos y apoyo constante.

Al Dr. Octavio por la orientación y paciencia que me ayudaron a enfocar me.

A mi madre Evelyn por acompañarme en cada paso cada día.

A mi padre Josué por incentivar me desde un punto de vista diferente

A mi pareja Evelyn por apaciguar mi mente en momentos de desenfoque.

# CONTENIDO

1.	INTRODUCCIÓN.	13
1.1.	CONTEXTO DEL PROBLEMA.	13
1.2.	PLANTEAMIENTO DEL PROBLEMA	16
1.3.	JUSTIFICACIÓN.	18
1.4.	OBJETIVOS.	19
1.4.1.	<i>Objetivo general.</i>	19
1.4.2.	<i>Objetivos específicos.</i>	19
1.5.	HIPÓTESIS	20
1.6.	ORGANIZACIÓN DE LA TESIS.	20
2.	MARCO TEÓRICO	22
2.1.	ÚTERO.	22
2.1.1.	<i>Anatomía.</i>	22
2.1.2.	<i>Orientación.</i>	24
2.2.	FIBROMAS UTERINOS	25
2.2.1.	<i>Tipos</i>	26
2.2.2.	<i>Epidemiología y factores de riesgo.</i>	27
2.2.3.	<i>Síntomas.</i>	30
2.2.4.	<i>Diagnóstico.</i>	30
2.2.5.	<i>Tratamiento.</i>	31
2.2.6.	<i>Tratamiento Farmacológico.</i>	32
2.2.7.	<i>Tratamiento quirúrgico tradicional.</i>	32
2.2.8.	<i>Procedimientos mínimamente invasivos.</i>	32
2.3.	ULTRASONIDO (ECOGRAFÍA).	33
2.4.	INTELIGENCIA ARTIFICIAL.	33
2.4.1.	<i>Inteligencia artificial en la medicina.</i>	35
2.4.2.	<i>Visión Artificial.</i>	36
2.4.3.	<i>Redes neuronales convolucionales (CNN).</i>	36
2.4.4.	<i>Antecedentes en diagnóstico de fibromas con IA.</i>	38
2.5.	ESTADO DEL ARTE: DETECCIÓN DE FIBROMAS UTERINOS EN IMÁGENES MÉDICAS.	39
3.	DESCRIPCIÓN DE LA SOLUCIÓN PROPUESTA.	43

3.1.	METODOLOGÍA.	44
3.2.	CRITERIOS DE INCLUSIÓN Y EXCLUSIÓN.	46
4.	RESULTADOS.	47
4.1.	CONFORMACIÓN DEL CONJUNTO DE DATOS FASE 1 (TRANSPÉLVICO).	47
4.1.	PREPROCESAMIENTO FASE 1 (TRANSPÉLVICO).	48
4.2.	<i>División del conjunto de datos fase 1 (Transpélvico)</i>	48
4.3.	<i>Entrenamiento de la red fase 1 (Transpélvico).</i>	53
4.4.	<i>Entrenamiento y validación de la red fase 1 (Transpélvico).</i>	54
4.5.	<i>Conformación del conjunto de datos fase 2 (Endocavitario).</i>	58
4.6.	<i>Preprocesamiento y división de los datos fase 2 (Endocavitario).</i>	58
4.7.	<i>Entrenamiento y validación de la red fase 2 (Endocavitario).</i>	59
5.	DISCUSIÓN DE RESULTADOS	65
6.	CONCLUSIONES	66
	REFERENCIAS	67

# Índice de Figuras.

<i>Figura I. Tasa de hospitalización por diagnóstico ginecológico y grupo de edad (1998–2005). Adaptado de [9].</i>	14
<i>Figura II. Partes del útero. Adaptado de [20]</i>	23
<i>Figura III. Orientaciones uterinas. Adaptado de [20]</i>	24
<i>Figura IV. Representación de un útero con diferentes tipos de miomas.</i>	25
<i>Figura V. Comparación con otras enfermedades (costos anuales en E.U., USD 2010). Adaptado de [27].</i>	26
<i>Figura VI. Tipos de fibromas uterinos. Adaptado de [21]</i>	27
<i>Figura VII. Tasa relativa de casos de miomas según raza.</i>	27
<i>Figura VIII. Subgrupos IA. (Elaboración Propia)</i>	34
<i>Figura IX. Capas de una CNN (Elaboración Propia)</i>	37
<i>Figura X. Diagrama de las fases requeridas para el proceso de aprendizaje supervisado (elaboración propia).</i>	43
<i>Figura XI. Metodología general.</i>	44
<i>Figura XII. Ejemplo de una imagen transpelvica etiquetada con mioma.</i>	48
<i>Figura XIII. Métricas de precisión y Recall experimento C-2, conjunto 1.</i>	55
<i>Figura XIV. Matriz de confusión experimento C-2</i>	55
<i>Figura XV. Grafica Recall - Confidence experimento C-2 conjunto 1.</i>	56
<i>Figura XVI Ejemplos de inferencia experimento C-2 conjunto 1.</i>	56
<i>Figura XVII. Matriz experimental experimento F-1 conjunto 1.</i>	57
<i>Figura XVIII. Ejemplo de imagen endocavitaria etiquetada con mioma.</i>	59
<i>Figura XIX. Graficas de Precisión y Recall de experimento A-2 conjunto 2.</i>	59
<i>Figura XX. Graficas de Precisión y Recall de experimento G-1 conjunto útero pipeline en cascada.</i>	60
<i>Figura XXI. Matriz de confusión de experimento G-1 conjunto útero pipeline en cascada.</i>	60
<i>Figura XXII. Recortes de útero obtenido de etapa 1 pipeline en cascada.</i>	61
<i>Figura XXIII. Matriz de confusión experimento con etiquetas vacías segunda etapa pipeline en cascada.</i>	62
<i>Figura XXIV. Graficas de experimento con etiquetas vacías segunda etapa pipeline en cascada.</i>	62
<i>Figura XXV. Ejemplo de imagen de etapa dos de pipeline en cascada con etiquetado contextual.</i>	63
<i>Figura XXVI. Graficas de precisión &amp; Recall de etapa dos de pipeline en cascada con etiquetado contextual.</i>	64
<i>Figura XXVII. Matriz de confusión de etapa dos de pipeline en cascada con etiquetado contextual.</i>	64



# Índice de Tablas.

<i>Tabla I. Factores personales y reproductivos asociados a miomas. ....</i>	<i>28</i>
<i>Tabla II. Comorbilidades médicas asociadas a miomas. ....</i>	<i>29</i>
<i>Tabla III. Opciones de tratamiento farmacológico para miomas. Adaptado de [33], [42]. ....</i>	<i>32</i>
<i>Tabla IV. Opciones de tratamiento quirúrgico tradicional para miomas. Adaptado de [11], [42]. ....</i>	<i>32</i>
<i>Tabla V. Opciones de procedimientos mínimamente invasivos como tratamiento para miomas. Adaptado de [42]. ....</i>	<i>32</i>
<i>Tabla VI. Estado del arte. ....</i>	<i>42</i>
<i>Tabla VII. características de las imágenes del banco de datos de [15] . ....</i>	<i>47</i>
<i>Tabla VIII. Características contextuales del conjunto 1. ....</i>	<i>47</i>
<i>Tabla IX. Configuraciones iniciales propuestas conjunto 1. ....</i>	<i>53</i>
<i>Tabla X. Configuraciones secundarias de entrenamiento conjunto 1. ....</i>	<i>54</i>
<i>Tabla XI. Resumen de resultados de experimentos conjunto 1. ....</i>	<i>54</i>
<i>Tabla XII. Resumen de recolección de imágenes nacionales. ....</i>	<i>58</i>

# Capítulo 1.

## 1. Introducción.

### 1.1. Contexto del problema.

Los fibromas uterinos, también llamados miomas, entre otros sinónimos, corresponden a tumoraciones benignas con origen en la capa muscular del útero (miometrio) [1] [2]. A pesar de que una cantidad relevante de los casos correspondientes a este trastorno ginecológico resulta clínicamente silente, no se debe perder de vista que representan uno de los tumores con mayor prevalencia en mujeres en todo el mundo con un estimado general del 70% [3] [4]. Algunos estudios realizados muestran que la población afectada consiste principalmente en mujeres en edad reproductiva, es decir a partir del primer ciclo menstrual hasta la menopausia, aunque manteniendo cierta prevalencia aun después de esta última.

Por otro lado, es importante mencionar que de los datos se pueden tomar dos vertientes, las pacientes sintomáticas y asintomáticas, lo cual, aunado a otras variaciones como lo son el rango de edad, la raza, la paridad, los métodos de diagnóstico, entre otras características en común del grupo que se estudie, agrava la complejidad de obtener datos de la prevalencia exacta de este padecimiento, aunque, se ha observado una tendencia similar para ambos casos [5] [6].

Como mencionan diferentes estudios y revisiones, dentro de la cohorte sintomática, se manifiestan principalmente afecciones como sangrado abundante asociado al periodo menstrual, anemia derivada de un sangrado profuso, dolor pélvico igualmente presente durante el periodo o que en algunos otros casos persiste independientemente de la etapa del ciclo ginecológico [5], síntomas compresivos como pueden ser afectaciones al tránsito intestinal, como puede ser estreñimiento o dispareunia; siendo otro síntoma de origen similar, la pérdida involuntaria de orina [7], mayor riesgo de resultados negativos en la salud reproductiva, a tal punto que la infertilidad, en algunos casos, encuentra su origen en la presencia de miomas. [4]. Los resultados de una revisión de Pritts y

colaboradores, mencionan que existen casos significativamente menores de implantación y embarazo en comparación con mujeres que no presentan miomas, de igual forma la tasa de interrupción espontánea del embarazo es significativamente mayor en presencia de estas tumoraciones [8].

Se han realizado estudios que refuerzan la estimación de la prevalencia de los fibromas uterinos y al compararlo con otras afecciones ginecológicas, permiten visualizar su impacto entre las pacientes, siendo la que presenta mayor tasa de hospitalizaciones (Figura I), tal como lo expone Whiteman [9], dejando también a la vista la carga que representa para el sistema de salud.




Figura I. Tasa de hospitalización por diagnóstico ginecológico y grupo de edad (1998–2005). Adaptado de [9].

Las intervenciones quirúrgicas como tratamiento son frecuentemente indicadas para tratar este padecimiento, sin embargo existen razones para ser cauteloso con este tipo de procedimientos, la mayoría debido riesgos asociados como, infección, daño a los tejidos contiguos, transfusiones de productos sanguíneos, adherencias postoperatorias; en cuanto al ámbito reproductivo se asocian mayor susceptibilidad a la rotura uterina e incremento en la necesidad de cesárea [8]. Por lo que un monitoreo y diagnóstico efectivo, resultan en gran manera una prioridad para evaluar correctamente de qué forma abordar los miomas.

La histerectomía es la cirugía ginecológica más común, con más de 600,000 procedimientos al año en Estados Unidos [10]; de forma independiente, se señala

que 90% de estas intervenciones se realizan por causas benignas, siendo los fibromas uterinos la principal razón [11]. Estas neoplasias siguen siendo una de las principales causas de histerectomía, lo que destaca la importancia de tratar este problema en la salud ginecológica.

Para poder ser diagnosticados, se comienza con la evaluación de los síntomas mencionados anteriormente, otros como pesadez y sensación de presión y un examen superficial sobre el abdomen, estos síntomas pueden ser similares a otras condiciones pélvicas por lo que se debe apoyar de un método de imagen, para lo cual como bien lo menciona McLucas *“La selección de una técnica de imagen debe incluir una evaluación tanto de los beneficios como de los costos asociados con el procedimiento.”* [12]

La imagenología ofrece diferentes técnicas como la ecografía (ultrasonido, US), resonancia magnética (RM), tomografía computarizada (TC), con el fin de determinar el número, tamaño y posición de los miomas. Cada técnica tiene sus ventajas y limitaciones, en algunos casos incluso contraindicaciones, por ejemplo, durante el embarazo. La técnica más socorrida suele ser el ultrasonido, pues se considera seguro, suele presentar una alta disponibilidad y un costo menor comparado con otras técnicas de imagen, pues si bien por ejemplo la resonancia magnética, permite visualizar y medir de forma más precisa diferentes estructuras internas; para la mayor parte de las aplicaciones médicas, el incremento en el precio no está justificado [1] [12].



## 1.2. Planteamiento del problema

La ecografía es la técnica de imagen más empleada para la evaluación uterina debido a su relación costo-beneficio favorable. No obstante, estudios publicados señalan una sensibilidad y especificidad variables; en consecuencia, la ecografía aún presenta áreas de oportunidad para optimizar su precisión diagnóstica en fibromas uterinos [8]. Una de las causas de la variabilidad en la efectividad de esta técnica, es la subjetividad que se genera entre un observador u otro, derivado del entrenamiento del operador del ecógrafo, así como de la experiencia de quien interpreta la imagen, siendo dependiente de ello la eficacia de este método de imagen [13]. En adición a las dificultades, las imágenes obtenidas por ecografía suelen mostrar características difusas que complican la detección de masas [14].

Como ya se mencionó, esta ambigüedad visual se acentúa especialmente en profesionales con menor experiencia, y puede agravarse por factores como la fatiga asociada a extensas jornadas laborales, puesto que, en la práctica médica, habitualmente, se depende de estas imágenes como un primer acercamiento que frecuentemente se queda como el único estudio realizado, requiriendo de tiempo y atención, siendo susceptible a errores humanos, lo que disminuye aún más la precisión diagnóstica y por ende, en decisiones terapéuticas inadecuadas o procedimientos quirúrgicos innecesarios.

Existe una falta de herramientas que refuercen las técnicas de imagen para mejorar la precisión diagnóstica, en este caso, de la ecografía, dichas herramientas podrían disminuir los efectos de la subjetividad y variabilidad evitando la omisión de tratamientos oportunos y agilizando un monitoreo adecuado [15]. Hay una tendencia creciente en el uso de inteligencia artificial (IA) en el ámbito médico y como tal en la imagenología, en herramientas que apoyan al especialista médico en el diagnóstico y toma de decisiones. Siendo para el caso de la implementación en imágenes, las redes neuronales convolucionales (CNN por sus siglas en inglés), una propuesta que ha mostrado resultados prometedores pues presentó un desempeño pertinente en la identificación de patrones complejos en las imágenes médicas [16]. Ya se han realizado trabajos a nivel académico, que incursionan en el uso de estos algoritmos para el análisis de imágenes con fibromas, que, si bien muestran resultados pertinentes, presentan limitaciones en capacidad de procesamiento y velocidad [17] [18]; considerando además, el constante avance en el campo del

aprendizaje profundo, en el cual se presentan algoritmos cada vez más novedosos, se vuelve crucial el desarrollo de herramientas novedosas que complementen al especialista médico.

Por este motivo, el presente proyecto busca optimizar el análisis de imágenes ecográficas para el manejo clínico de los fibromas uterinos mediante la implementación de técnicas de Inteligencia Artificial.

### 1.3. Justificación.

Un diagnóstico certero y un monitoreo eficaz permiten al médico tomar decisiones oportunas sobre el tratamiento los fibromas uterinos, así mismo, la detección precisa le facilita al especialista la diferenciación con otras afecciones que pueden resultar similares [12]. Anteriormente, la identificación de fibromas uterinos dependía en gran medida de la experiencia y habilidad del radiólogo, lo que podía llevar a variaciones en los resultados, pero apoyado en las CNN, este proceso se estandariza, minimizando la posibilidad de errores humanos y proporcionando una mayor consistencia en los diagnósticos.

En la práctica médica, se analizan y segmentan imágenes de ultrasonido en volumen, la utilización de herramientas de apoyo que implementan IA, pueden brindar información precisa y reproducible para tomar decisiones acertadas respecto al proceder con el paciente, pues son capaces de en una fracción de segundo, identificar patrones complejos que pueden ser difíciles de discernir para un humano sin suficiente entrenamiento, experiencia o bajo condiciones de fatiga, mejorando la exactitud del diagnóstico y acortando el tiempo necesario para su interpretación. [16].

## 1.4. Objetivos.

### 1.4.1. Objetivo general.

**“Desarrollar un sistema inteligente basado en redes neuronales convolucionales para la detección y segmentación automática de fibromas uterinos en imágenes de ultrasonido”.**

### 1.4.2. Objetivos específicos.

- Conformar un banco de imágenes que incluya imágenes de casos reales de fibromas uterinos, provenientes de una cohorte de la población mexicana.
- Realizar el etiquetado del objeto de interés, guiado por especialista médico.
- Examinar múltiples configuraciones de entrenamiento para optimizar el desempeño de la red neuronal seleccionada, para el conjunto de datos previamente establecido.
- Diseñar un algoritmo que emplee redes neuronales convolucionales que permita la detección y segmentación de fibromas uterinos en imágenes de ultrasonido.
- Ejecutar pruebas para evaluar la asertividad y eficiencia del algoritmo.
- Analizar la viabilidad del sistema como herramienta de apoyo para médicos generales o especialistas en formación, enfocándose en su utilidad clínica y aplicabilidad en contextos reales.



## 1.5. Hipótesis

Es posible mediante el procesamiento de imágenes ecográficas y el ajuste de hiperparámetros, es posible optimizar un modelo de visión por computadora que, entrenado con ecografías reales de la población mexicana (con fibromas y con la referencia anatómica del útero), identifique con alta precisión la presencia y la ubicación de los miomas.

## 1.6. Organización de la tesis.

El documento presente, está estructurado en 5 capítulos que describen de forma progresiva el desarrollo de lo propuesto a fin de alcanzar los objetivos planteados.

### Capítulo 1 – Introducción

Se expone el contexto clínico y técnico e importancia del problema que presenta el diagnóstico de fibromas uterinos así como la justificación y objetivos a cumplir.

### Capítulo 2 – Marco teórico

Señala conceptos técnicos y médicos de las dos áreas implicadas en este proyecto de naturaleza interdisciplinaria como lo es la médica y la de inteligencia artificial.

### Capítulo 3 – Descripción de la solución propuesta

Se detalla la metodología general, los criterios de selección de datos y las fases del aprendizaje supervisado implicadas.

#### Capítulo 4 – Resultados

Se presentan los hallazgos obtenidos de lo propuesto en la metodología y las vertientes que surgieron siguiendo esta misma.

#### Capítulo 5 - Discusión de resultados

Se discuten los resultados obtenidos

#### Capítulo 6 – Conclusiones parciales

Se sintetizan respuestas a objetivos/hipótesis y se proponen líneas futuras.

# Capítulo 2.

## 2. Marco Teórico

### 2.1. Útero.


El útero o matriz es un órgano que forma parte del aparato reproductor femenino, en el cual se lleva a cabo la implantación y desarrollo del ovulo ya fecundado, hasta la etapa de madurez, en la que es expulsado. Está ubicado en la parte inferior del abdomen, a la altura de la pelvis, tiene la forma de una pera hueca y está compuesto por musculo liso, esto se refiere a que es un musculo del cual no se tiene control consciente [19] [20]. Las medidas comunes de este órgano son:

- Longitud: 7–8 cm
- Grosor: 2,5–4 cm
- Ancho: 4–5 cm

#### 2.1.1. Anatomía.

De forma general el útero se compone de 4 partes, el fondo, el cuerpo, el istmo y el cuello como puede observarse por color en la Figura II [21].

El cuello del útero es la curvatura superior que tiene un ancho mayor. El cuerpo es la parte más grande en él se encuentran las aberturas laterales superiores que conducen a las trompas de Falopio; también se encuentra en el la mayor parte de la cavidad uterina la cual tiene forma de triángulo invertido. El istmo es el estrechamiento que se encuentra debajo del cuerpo y es el punto de transición entre el cuerpo y el cuello. Por último, el cuello o cérvix, es la estructura cilíndrica que conduce a la vagina [20] [22] [23].



*Figura II. Partes del útero. Adaptado de [20]*

Adicionalmente, el útero está compuesto por tres capas, definidas por características morfológicas y funcionales en particular y que en conjunto permiten al útero cumplir con procesos esenciales:

**Perimetrio o serosa**, es la capa externa del útero que forma parte del revestimiento seroso que recubre la mayoría de las estructuras del abdomen, consiste en una membrana cuya función es proteger al órgano y reducir la fricción con el tejido circundante.


**Miometrio**, constituye la capa media y es la más gruesa de las tres, como tal es el músculo que tiene la capacidad de generar contracciones con diversos propósitos en el proceso reproductivo. Está compuesto de haces de músculo liso organizados en capas longitudinales.

**Endometrio**, es la capa interna, intermedia entre el cuerpo y la cavidad uterina, está compuesta por mucosa y es altamente sensible a las hormonas que se presentan en los cambios cíclicos de la regla femenina, sufre un proceso de proliferación para crear un ambiente receptivo ante una potencial implantación embrionaria, y experimenta descamación cuando no ocurre la fecundación, lo que se manifiesta clínicamente como flujo menstrual [22] [21].



### 2.1.2. Orientación.

La condición anatómica normal del útero es en la cavidad pélvica, entre la vejiga y el recto, y suele presentar una orientación hacia adelante, conocida como anteversión y ante flexión. Estas posiciones facilitan la alineación con el canal vaginal y favorecen el proceso de fecundación. No obstante, existen otras variantes como la posición media, la retroversión o la retroflexión, en las que el útero se inclina o flexiona hacia atrás. Reconocer estas orientaciones es clínicamente relevante, ya que su identificación previa a procedimientos ginecológicos permite minimizar riesgos, como la perforación uterina, en la Figura III podemos observar estas variaciones. La evaluación puede realizarse mediante examen clínico o estudios de imagen como el ultrasonido [20].



*Figura III. Orientaciones uterinas. Adaptado de [20]*

## 2.2. Fibromas uterinos

También llamados miomas uterinos, son tumoraciones que aparecen con frecuencia en el útero de las mujeres, sobre todo en edad fértil, se estima que en alrededor del 70% de las mujeres en el mundo, especialmente las mujeres de raza afrodescendiente. Aunque no son neoplasias malignas, sí pueden causar problemas de salud importantes, entre el 25% y 40% de los casos de miomatosis presentan síntomas que merman la calidad de vida y afectan negativamente las actividades diarias de las pacientes [6] [24] [25]. Estos miomas se forman a partir del músculo del útero (miometrio) y están compuestos de colágeno y otras proteínas [26]. Las hormonas del cuerpo parecen influir en su crecimiento, porque casi nunca aparecen antes de que una mujer tenga su primera menstruación y suelen disminuir después de la menopausia.



*Figura IV. Representación de un útero con diferentes tipos de miomas.*

Además de representar una condición ginecológica frecuente, resultan una carga significativa que afecta los sistemas de salud. El estudio realizado por Cardozo y colaboradores [27], profundiza en el impacto económico de este padecimiento en los estados unidos, cuyos resultados comparativos se pueden observar en la figura V.




Figura V. Comparación con otras enfermedades (costos anuales en E.U., USD 2010). Adaptado de [27].

### 2.2.1. Tipos

Dependiendo de dónde están ubicados en el cuerpo uterino o a su alrededor (aunque también es posible hallarlos en el cuello uterino), se pueden clasificar en tres categorías, como subserosos, intramurales o submucosos, y pueden aparecer solos o en varios al mismo tiempo (es decir, una misma paciente puede presentar un único mioma o múltiples miomas simultáneamente, incluso de tipos y tamaños distintos, en diferentes zonas) [2].

Con una estadística estimada de 55% de hallazgos para miomas subserosos, 40% intramurales y 5% submucosos. Como se puede observar en la figura VI, los de tipo subseroso se ubican en la pared externa del útero, los de tipo intramural se ubican en la capa muscular de la pared uterina y, por último, los de tipo submucoso que protruyen desde la capa muscular en dirección a la cavidad uterina [21].




Figura VI. Tipos de fibromas uterinos. Adaptado de [21]

### 2.2.2. Epidemiología y factores de riesgo.

EL grupo étnico de la cohorte poblacional a estudiar influye en la prevalencia de los fibromas uterinos como se puede observar en la figura VII,




Figura VII. Tasa relativa de casos de miomas según raza.

así como factores demográficos, del entorno social y la edad siendo cada uno de ellos determinante en el riesgo de presentar la afección [28] [29] [30].

La predisposición de presentar miomas a edades más tempranas y con mayor carga sintomática es influida por variables genéticas, hormonales, ambientales y sociales [28] [30]. Se ha observado de forma consistente que las mujeres afrodescendientes presentan la prevalencia más alta [6] [31]. Para mujeres latinoamericanas de entre 35 a 50 años, se estima que entre el 20% y 50%, padecen de fibromas uterinos [22].

A continuación, en la Tabla I, se presentan factores personales y reproductivos identificados en estudios especializados ( [29], [30], [31], [32]) , así como en la Tabla 2 las comorbilidades médicas, a fin de visualizar **factores de riesgo, presentación temprana y condiciones médicas asociadas**, incluyendo a mujeres jóvenes, tanto sintomáticas como asintomáticas.

FACTOR	EVIDENCIA ENCONTRADA
EDAD AVANZADA (>40 AÑOS).	Mayor prevalencia en mayores de 40 años.
EDAD JOVEN (18–30 AÑOS).	26 % de mujeres negras asintomáticas ya presentaban miomas.
EDAD TEMPRANA DE MENARQUIA.	Factor conocido de riesgo.
MULTIPARIDAD (2 O MÁS EMBARAZOS).	Asociada con mayor frecuencia de miomas.
HISTORIA DE ABORTOS ESPONTÁNEOS.	26.3 % de las mujeres con miomas lo habían experimentado.
AUSENCIA DE SÍNTOMAS CLÍNICOS.	El 74 % de mujeres negras con miomas entre 18–30 años eran asintomáticas, lo que refuerza la importancia del ultrasonido en etapas tempranas.

*Tabla I. Factores personales y reproductivos asociados a miomas.*

CONDICIÓN ASOCIADA	EVIDENCIA ENCONTRADA
HIPERTENSIÓN ARTERIAL	Frecuente entre mujeres con miomas en estudio de Puerto Rico.
DIABETES MELLITUS	Asociada en el perfil clínico.
QUISTES OVÁRICOS	Presentes en 52.2 % de las mujeres con miomas.
SANGRADO UTERINO ANORMAL (SUA)	37.8 % en pacientes con miomas.
ENDOMETRIOSIS	Muchas mujeres evaluadas fueron seleccionadas por sospecha de endometriosis; se sugiere coexistencia.
ALTA DENSIDAD ENDOMETRIAL	Encontrada por ultrasonido en mujeres negras jóvenes, incluso sin síntomas ni uso hormonal; posible marcador biológico.

*Tabla II. Comorbilidades médicas asociadas a miomas.*

### 2.2.3. Síntomas.

Entre las mujeres que presentan fibromas uterinos, una proporción significativa de los casos es asintomática, mientras que entre un 30% a 50% advierten sintomatología que afecta su calidad de vida [33].

Uno de los síntomas más frecuentes es el sangrado anormal ya sea presentado como menorragia (menstruaciones prolongadas) o de forma independiente al periodo menstrual, esto puede generar síntomas secundarios como síntomas como fatiga, letargo o palidez, hasta escalar a una anemia ferropénica [34] [35]. Otro síntoma que a menudo acompaña a otros es el dolor abdominal, presentado como una sensación de presión y pesadez, o también conllevar aunque no necesariamente, dolor lumbar o dispareunia (dolor durante las relaciones sexuales), especialmente en tumoraciones de gran tamaño que distorsionan la forma del útero y presiona tejidos y órganos adyacentes, lo cual ocasiona otro síntoma descrito de forma general como afecciones compresivas, que en este caso incluyen, micción frecuente, urgencia urinaria o retención, síntomas gastrointestinales como estreñimiento o dolor rectal [34] [36].

En cuanto al ámbito reproductivo, los miomas pueden dificultar el embarazo porque a veces bloquean el paso de los espermatozoides o afectan la implantación del embrión. Además, están relacionados con problemas durante el embarazo, como abortos espontáneos, partos prematuros o la necesidad de parto por cesárea [33].

### 2.2.4. Diagnóstico.

Un diagnóstico completo se fundamenta en la combinación del análisis de la historia clínica, el examen físico ginecológico, y pruebas de imagen [34]



[37]. La primera técnica de imagen indicada es el ultrasonido de preferencia con el transductor endocavitario, ya que la ecografía transvaginal ofrece una alta sensibilidad y especificidad con una accesibilidad elevada y a un bajo costo [38] [39].

La resonancia magnética es otra técnica de imagen, más comúnmente utilizada como evaluación preoperatoria dependiendo de las características del tumor en cuestión, esta igualmente resulta una técnica precisa, sin embargo, el costo es considerablemente elevado por lo que la elección de esta suele estar sujeta a la complejidad del caso a evaluar [35] [40].

Otras técnicas, que se consideran complementarias y cuyo uso es de igual forma situacional son la sonohisterografía y la histeroscopia diagnóstica, pues con ellas es posible visualizar la cavidad uterina, por lo que para esta afección principalmente sería de utilidad para evaluar miomas submucosos [21] . Hay que tener en cuenta que los síntomas de los miomas pueden confundirse con los de otras enfermedades ginecológicas, como la endometriosis o el síndrome de ovario poliquístico por lo que las técnicas de imagen resultan indispensables [36].

### 2.2.5. Tratamiento.

El tratamiento por elegir depende de la severidad de los síntomas, la edad de la paciente, su deseo reproductivo y las características anatómicas de los miomas, como tamaño, cantidad, ubicación [41]. Existen 3 tipos principales de tratamiento, el tratamiento farmacológico, el tratamiento quirúrgico tradicional y procedimientos mínimamente invasivos.

### 2.2.6. Tratamiento Farmacológico.

TIPO DE TRATAMIENTO	EJEMPLOS	COMENTARIOS
ANTAGONISTAS DE GNRH (HORMONA LIBERADORA DE GONADOTROPINA)	Leuprolida, Goserelina	Reducen tamaño y sangrado; causan síntomas menopáusicos y pérdida ósea; uso preoperatorio
ANTAGONISTAS DE GNRH	Elagolix	En investigación; inicio rápido y menos efecto de flare.
MODULADORES DEL RECEPTOR DE PROGESTERONA (SPRMS)	Mifepristona, Asoprisnil, Ulipristal	Reducen volumen y sangrado con menos efectos adversos; algunos en evaluación
ANTICONCEPTIVOS HORMONALES / DIU CON LEVONORGESTREL	DIU con levonorgestrel	Controlan sangrado, pero no reducen el tamaño; riesgo de expulsión si hay miomas submucosos
OTROS (AINES, HIERRO, ETC.)	AINES, hierro, inhibidores de aromatasa, danazol, caveolina	Resultados variables; algunos en investigación

Tabla III. Opciones de tratamiento farmacológico para miomas. Adaptado de [33], [42].

### 2.2.7. Tratamiento quirúrgico tradicional.

PROCEDIMIENTO	DESCRIPCIÓN
MIOMECTOMÍA	Extirpación de miomas conservando el útero; preferida si se desea fertilidad
HISTERECTOMÍA	Extirpación total del útero; opción definitiva en casos severos o sin deseo de fertilidad

Tabla IV. Opciones de tratamiento quirúrgico tradicional para miomas. Adaptado de [11], [42].

### 2.2.8. Procedimientos mínimamente invasivos.

PROCEDIMIENTO	DESCRIPCIÓN
EMBOLIZACIÓN DE ARTERIAS UTERINAS (UAE)	Reduce el flujo sanguíneo al mioma; eficaz, pero puede afectar fertilidad
ULTRASONIDO FOCALIZADO GUIADO POR RM (MRGFUS)	Permite tratar miomas ambulatoriamente sin incisión; aprobado en ciertos países
ABLACIÓN POR RADIOFRECUENCIA, MIÓLISIS, CRIOMIOLISIS	Métodos experimentales que destruyen el tejido fibromatoso sin extirparlo

Tabla V. Opciones de procedimientos mínimamente invasivos como tratamiento para miomas. Adaptado de [42].

## 2.3. Ultrasonido (Ecografía).

La ecografía, sobre todo la transvaginal, es uno de los métodos más usados para detectar y estudiar los miomas uterinos. Básicamente, funciona con ondas de sonido que rebotan en los tejidos y crean imágenes del útero en tiempo real [43].

A pesar de su amplio uso, presenta limitaciones, la calidad de las imágenes ecográficas puede verse comprometida por la presencia de ruido, un tipo de interferencia granular que es común en la adquisición de este tipo de imágenes, reduce la resolución y el contraste, dificultando la diferenciación entre tejido sano y patológico a los ojos del especialista [44] , entre otros artefactos y variación situacional en la captura de las imágenes.

En contraste, en estudios recientes se ha mejorado la ecografía usando programas de computadora que ayudan a delimitar con más precisión los bordes de los miomas. Estos métodos analizan las imágenes para distinguir mejor las regiones ocupadas [43] [45].

## 2.4. Inteligencia artificial.


La inteligencia artificial es una rama interdisciplinaria de la informática que busca desarrollar sistemas capaces de realizar tareas que requieren inteligencia biológica, como razonar, aprender, percibir o tomar decisiones basadas en la información que reciben de su entorno.

Dentro de la inteligencia artificial existen subgrupos con diferentes características en los procesos que realizan y diferencias en complejidad computacional, es importante tener esto en cuenta a la hora de evaluar el tipo de

algoritmo pertinente a aplicar pues si bien el aprendizaje profundo es parte del aprendizaje automático y de la inteligencia artificial, no son sinónimos [46] [47]. El aprendizaje automático utiliza principalmente métodos estadísticos para que los algoritmos reconozcan patrones a partir de datos estructurados, sin necesidad de que sean programados específicamente para cada tarea lo que resulta especialmente útil en áreas como el análisis financiero o en estrategias de marketing.

En cuanto al aprendizaje profundo es una variante especializada dentro del aprendizaje automático que emplea redes neuronales artificiales inspiradas en el funcionamiento del cerebro humano logrando aprender directamente de datos no estructurados como imágenes, audios o textos, siendo muy eficaz en resolver problemas complicados como reconocer objetos o interpretar la voz humana. A diferencia del aprendizaje automático tradicional, el aprendizaje profundo destaca por su capacidad para extraer automáticamente características relevantes durante su entrenamiento, eliminando la necesidad de definir manualmente estos atributos.

Sin embargo, ambos enfoques tienen sus desafíos pues para obtener buenos resultados necesitan grandes cantidades de datos y una importante potencia computacional [48].



*Figura VIII. Subgrupos IA. (Elaboración Propia)*

### 2.4.1. Inteligencia artificial en la medicina.

Recientemente la inteligencia artificial se ha convertido en una verdadera revolución dentro del mundo médico, especialmente en cuanto al procesamiento de datos clínicos y al análisis de imágenes para diagnóstico. Los algoritmos de aprendizaje profundo, especialmente las redes neuronales convolucionales, han demostrado una capacidad competente para identificar patrones complejos en radiografías, resonancias y tomografías, alcanzando en algunos casos una precisión diagnóstica comparable a expertos radiólogos [49]. Estas herramientas no solo optimizan el flujo de trabajo clínico, sino que permiten detectar hallazgos sutiles que podrían pasar desapercibidos en la práctica tradicional.

Una de las contribuciones más destacadas de la inteligencia artificial en el ámbito médico es la automatización del análisis de imágenes diagnósticas, gracias al desarrollo de redes neuronales profundas. Estos modelos logran una notable eficacia en tareas como la clasificación, segmentación y predicción de patologías a partir de diferentes técnicas de imagen médica, tales como la tomografía computarizada, la resonancia magnética, el ultrasonido y radiografías [50] [51] [52].

En el contexto específico de la ginecología, la inteligencia artificial ha sido incorporada para apoyar el diagnóstico en condiciones complejas, como los trastornos endocrinos, neoplasias o patologías oncológicas. Un ejemplo destacado es el sistema GAID (Gynaecological Artificial Intelligence Diagnostics) [53] [54].

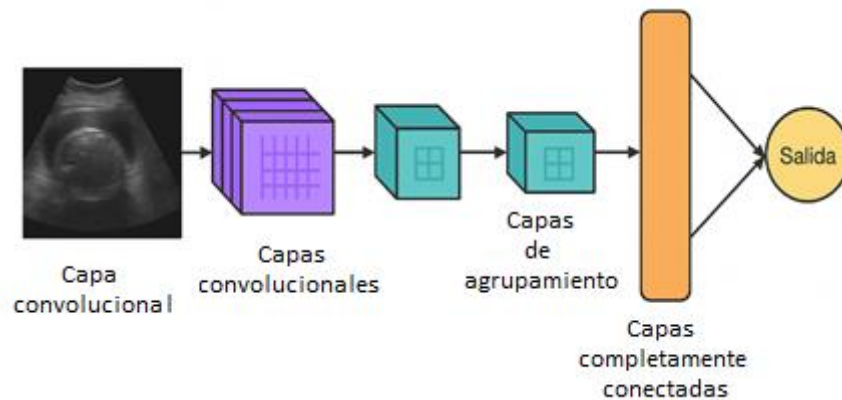
### 2.4.2. Visión Artificial.

La visión artificial, también conocida como visión por computadora, constituye un campo dentro de la inteligencia artificial cuyo propósito principal es dotar a las máquinas de la capacidad para interpretar el entorno visual. Esto implica la adquisición, procesamiento, análisis y comprensión de imágenes del mundo real con el fin de extraer información relevante. Como señala Szeliski [55], esta área busca automatizar funciones del sistema visual humano, tales como la identificación de objetos, la segmentación de imágenes o el seguimiento del movimiento, con el objetivo de replicar, de manera computacional, la interpretación visual humana.

### 2.4.3. Redes neuronales convolucionales (CNN).

Las redes neuronales convolucionales CNN, por sus siglas en inglés, representan una estructura ampliamente utilizada en el ámbito del aprendizaje profundo, particularmente en tareas relacionadas con el análisis de imágenes, pues están diseñadas para imitar cómo nuestro cerebro procesa lo que vemos [56], estas funcionan en capas, cada una especializada en detectar características diferentes. La arquitectura común de una CNN está compuesta por tres tipos de capas, comenzando por las capas convolucionales, que aplican filtros que se ajustan durante el proceso de entrenamiento para extraer características locales, las capas de agrupamiento o "pooling", que disminuyen la resolución para favorecer la generalización; y las capas completamente conectadas, que funcionan como clasificadores al interpretar lo aprendido [57], de esta manera se logra que el modelo aprenda automáticamente atributos relevantes, eliminando la necesidad de una selección manual de características [58].

Desde los años noventa, las CNN han demostrado ser altamente eficaces en tareas como clasificación de imágenes, segmentación semántica, detección de objetos y análisis volumétrico [52]. En el ámbito médico, han sido empleadas con éxito en el análisis de imágenes por resonancia magnética, tomografía computarizada y, particularmente, ultrasonido.



*Figura IX. Capas de una CNN (Elaboración Propia).*

#### 2.4.4. Antecedentes en diagnóstico de fibromas con IA.

Con el objetivo de reducir la subjetividad en la toma de decisiones respecto los fibromas uterinos, han surgido propuestas de apoyo en la toma de decisiones médicas, creadas a partir de diferentes algoritmos de diferente complejidad. Uno de estos trabajos es el de Campbell y colaboradores [59], quienes aplicaron aprendizaje automático y meta-aprendizaje en el ámbito médico. Usando datos de ocho clínicas, evaluaron más de 800 combinaciones de algoritmos, concluyendo que Naive Bayes con Adaboost era eficaz para tratamientos raros, mientras que J48 con Bagging funcionaba mejor para decisiones comunes. Plantearon un futuro donde estos modelos apoyarían decisiones clínicas personalizadas.

Poco después, Girija y Shashidhara [53], usaron el algoritmo J48 en WEKA para clasificar la gravedad de síntomas en pacientes con miomatosis uterina, logrando buenos resultados incluso con una base de datos limitada, lo que evidenció el valor de estas técnicas en diagnósticos.

Finalmente, Smith y colaboradores [60], desarrollaron un sistema más avanzado que recomendaba tratamientos personalizados para miomas uterinos. De los modelos probados, Gradient Boosting fue el más preciso (77%), demostrando el potencial del aprendizaje automático para apoyar decisiones clínicas considerando variables médicas y demográficas.



## 2.5. Estado del arte: Detección de fibromas uterinos en imágenes médicas.

Diversos estudios han abordado el desafío del análisis automatizado de imágenes médicas en la búsqueda de métodos eficientes, desde enfoques convencionales hasta propuestas más recientes basadas en inteligencia artificial. Entre estas, las técnicas que emplean aprendizaje profundo, y en particular las redes neuronales convolucionales, han mostrado un notable potencial para la identificación y clasificación de estructuras y patrones clínicamente significativos.

Un estudio de 2012 [44], aborda como propuesta un filtro de Lee mejorado para la eliminación de ruido en imágenes de ultrasonido, seguido de un algoritmo de segmentación basado en contornos y umbrales binarios para identificar la región del mioma. No se emplearon redes neuronales ni aprendizaje profundo, pero se utilizaron técnicas clásicas de procesamiento de imágenes asistidas por computadora. Se trabajó con un conjunto de 100 imágenes ecográficas de útero con miomas, y se compararon los resultados con las marcas de dos radiólogos. El algoritmo mostró resultados sólidos, alcanzando precisiones superiores al 95%, con sensibilidad y especificidad igualmente elevadas. Para 2014 el trabajo de Prabakar y colaboradores [61], con un enfoque similar, se centra en la segmentación y medición automática de miomas uterinos usando imágenes de ultrasonido, una modalidad común pero complicada por el ruido moteado.

A través de funciones morfológicas implementadas en la herramienta gráfica Vision Assistant de LabVIEW, los autores proponen una metodología basada en el algoritmo modificado de limpieza morfológica de imagen (MMIC) para la eliminación de ruido y segmentación del mioma. Se utiliza el detector de bordes

de Canny junto con operaciones morfológicas para definir contornos y extraer características como área, diámetro y perímetro del mioma. El sistema fue validado con imágenes de 10 pacientes, logrando una precisión del 90% en la segmentación. Mas recientemente en 2016, el estudio de Poonia [62], presenta un enfoque híbrido para la segmentación de imágenes de ultrasonido, centrado en delinear bordes de regiones afectadas por enfermedades, como quistes hepáticos, lo cual tiene gran relevancia clínica. Aunque el artículo no se centra específicamente en miomas uterinos, las técnicas descritas son aplicables al tratamiento de imágenes similares.

Sin embargo, estos enfoques podrían presentar sesgos y limitaciones debido a las características del conjunto de datos utilizado, la aparición de equipos de ultrasonido más recientes, entre otros factores.

Para 2019, Carvalho [63], evalúa la segmentación automática de ovarios y folículos en ecografías para detectar cáncer de ovario temprano. Se compararon dos redes neuronales (U-Net y FCRN) con distintos tipos de datos, destacando el modo B como el más efectivo. Aunque las redes rindieron de forma similar, el tipo de imagen influyó en la precisión, mostrando el potencial de la IA para mejorar diagnósticos y reducir cirugías innecesarias.

Con el paso del tiempo, continuaron apareciendo trabajos especializados en ginecología que ya integran el uso de redes neuronales convolucionales CNN, por ejemplo, en 2022, [64] se aplica inteligencia artificial para detectar automáticamente miomas uterinos en imágenes médicas. Usando el modelo VGG16 y un conjunto de 3000 imágenes del dataset TCGA-UCEC, se entrenó una red neuronal con excelentes resultados: 98.5% de precisión y F1 score del 98%. Gracias al preprocesamiento y aumento de datos, el sistema demostró un alto rendimiento, superando métodos anteriores y mostrando gran potencial para su uso clínico en apps móviles o plataformas digitales. Otros investigadores,

analizaron métodos de segmentación por aprendizaje profundo aplicados a tumores uterinos, como miomas, usando redes como U-Net y FCN. Estas técnicas, aplicadas a imágenes de resonancia y ecografía, mejoran la precisión diagnóstica sin centrarse en un solo dataset.

Para 2023 figura ya dentro del trabajo realizado, la red YOLO, la cual a tomado fuerza y mostrado actualizaciones importantes a la fecha que se escribe la presente tesis, en dicho año, se utilizó un modelo DCNN (YOLOv3 + ResNet50) para detectar automáticamente fibromas uterinos en imágenes de ultrasonido. El modelo logró una precisión del 94.26% y permitió que ecografistas junior alcanzaran un rendimiento diagnóstico comparable al de especialistas senior. Este enfoque demostró ser eficaz y eficiente, validado con un conjunto externo de 488 imágenes [65].

Los conjuntos de datos reducidos han sido un desafío constante en el desarrollo de este tipo de propuestas, por eso es que algunas de ellas se centran en ello, como en [15], que, presenta un modelo híbrido que combina MobileNetV2 con DCGAN para clasificar ecografías uterinas con y sin miomas. Con datos de dos hospitales, se usaron 1990 imágenes y se generaron 240 adicionales para equilibrar las clases. El modelo logró una alta precisión del 97.45% y un F1 score de 0.9741, demostrando gran efectividad a pesar del limitado volumen de datos médicos.

A continuación, en la tabla se presenta un resumen de lo expuesto en este apartado.

Autor, Año	Algoritmo / Modelo	Dataset	Tipo de imágenes	Algoritmo	Precisión	Comentarios
Saranya & Malarkhodi, 2012	Filtro Lee + contornos	100 imágenes	Ecografías uterinas	Filtro Lee + contornos	>95%	Para entornos de bajo recurso.
Prabakar et al., 2014	MMIC + Canny + morfología	10 pacientes	Ecografías uterinas	MMIC + Canny + morfología	90%	Sugiere implementación embebida.
Poonia et al., 2016	Umbral móvil + gradiente + morfología	6 pacientes	Ecografías hepáticas	Umbral móvil + gradiente + morfología	94.75%	Transferible a miomas; error promedio 5.25%.
Carvalho et al., 2019	U-Net, FCRN	107 imágenes	Ecografías transvaginales	U-Net, FCRN	DICE > 0.78	DL exitoso; B-modo mejor que datos crudos; útil para folículos/estroma.
Ahmed et al., 2022	VGG16	3000 imágenes	DICOM uterino (TCGA-UCEC)	VGG16	98.5%	Excelente rendimiento; ideal para apps web/móviles.
Sun et al., 2022	U-Net, FCN	No específico	RM y ecografías	U-Net, FCN	N/R	Revisión valiosa; destaca ventajas del DL para diagnóstico y planificación.
Ahmed et al., 2023	VGG16, VGG19, AlexNet	3000 imágenes	Ecografías DICOM (TCGA)	VGG16 (mejor)	98.5%	Comparativo detallado; VGG16 superior.
Cai et al., 2023	MobileNetV2 + DCGAN	1990 imágenes	Ecografías uterinas	MobileNetV2 + DCGAN	97.45%	Muy ligera y rápida (40 FPS); solución balanceada y clínica.
Liu et al., 2022	YOLOv3 + ResNet50	3870 imágenes	Ecografías uterinas	Detección automática	94.26%	Validación robusta externa.

Tabla VI. Estado del arte.

# Capítulo 3.

## 3. Descripción de la solución propuesta.

El presente proyecto, se desarrolla en torno a un modelo de inteligencia artificial, con un enfoque de aprendizaje supervisado, con un modelo que realice las tareas de detección y segmentación en imágenes reales de ultrasonido ginecológico en su modalidad endocavitaria, así como transpélvico. Para ello se utilizaron modelos que simulan las redes neuronales biológicas conocidas como redes neuronales artificiales, descritas en el marco teórico como parte del aprendizaje profundo, que a su vez forma parte de la inteligencia artificial. En las páginas siguientes, se describe la metodología de dos fases en las que para la primera se trabajó un conjunto de datos público de imágenes de ultrasonido adquiridas mediante la técnica transpélvica y para la segunda se conformó y trabajó sobre un conjunto de datos propio de pacientes mexicanas conformado por imágenes de ultrasonido adquiridas mediante la técnica endocavitaria gracias a la colaboración con la médico especialista Karen Eunice Hernández Allende, codirectora del presente trabajo.

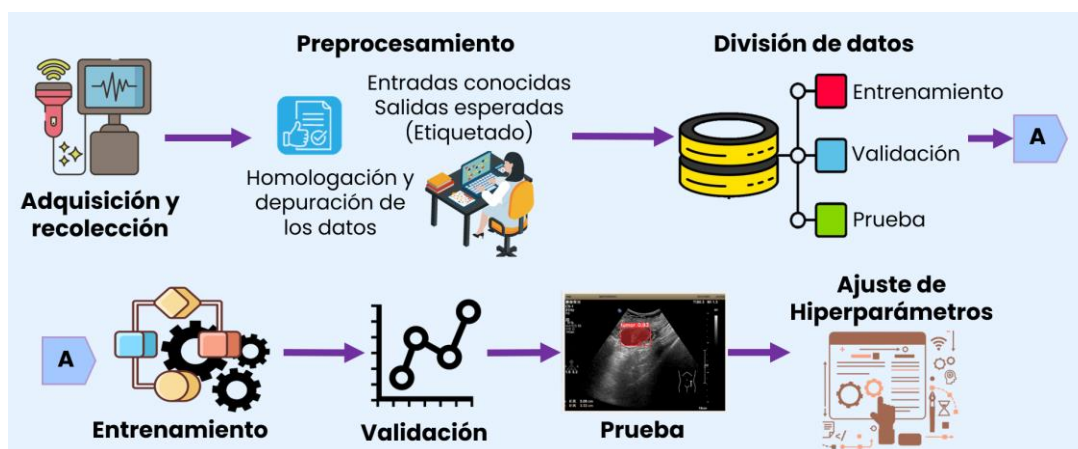


Figura X. Diagrama de las fases requeridas para el proceso de aprendizaje supervisado (elaboración propia).

### 3.1. Metodología.

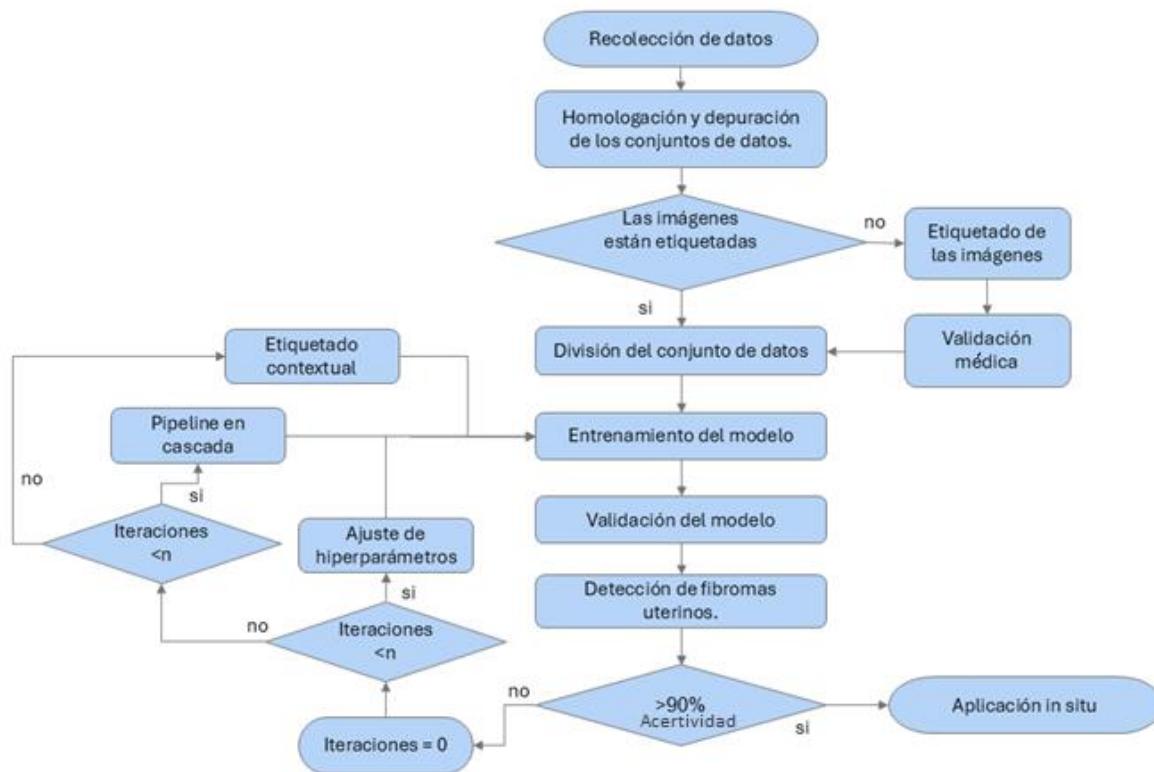


Figura XI. Metodología general.

La presente investigación inicia con un análisis exhaustivo de la disponibilidad de bancos de datos públicos reportados en la literatura que forma parte del estado del arte, con el objetivo de identificar aquellos que permiten el acceso libre o mediante solicitud formal. Paralelamente, se estableció colaboración directa con un médico especialista en el área de ginecología, quien participa activamente en el proyecto mediante la provisión de imágenes médicas propias y la validación clínica del etiquetado realizado sobre dichas imágenes.

Como resultado, se conformaron dos conjuntos de datos principales, integrados tanto por fuentes de acceso público como por datos aportados directamente por la especialista.

Estos conjuntos fueron sometidos a procesos de depuración y homologación para asegurar su coherencia, calidad y utilidad en función de los objetivos del estudio.

En los casos en los que las imágenes no contaban con etiquetas explícitas del objeto de interés, específicamente miomas uterinos, se procedió a un etiquetado manual cuyo proceso fue documentado meticulosamente en una bitácora, la cual posteriormente fue revisada junto con la especialista para garantizar la validez de las observaciones registradas.

Una vez verificados y completos, los conjuntos de datos fueron divididos en tres subconjuntos: entrenamiento (80%), validación (15%) y prueba (5%), siguiendo proporciones comunes en la literatura para problemas de clasificación médica con redes neuronales.

Posteriormente, se seleccionó y configuró un modelo de red neuronal, iniciando así el proceso de entrenamiento. La validación del modelo se llevó a cabo mediante el análisis de métricas estándar como Precisión, Recall, F1-Score y niveles de confianza, complementado con representaciones gráficas que permitieron evaluar el comportamiento del aprendizaje a lo largo de las épocas.

En caso de que los resultados obtenidos en la etapa de validación sean inferiores al 90% de asertividad, se procede a realizar un ajuste de hiperparámetros y se reinició el proceso de entrenamiento, repitiéndose este ciclo de manera iterativa, si después de varias iteraciones no se logra mejorar el desempeño significativamente, se implementa una arquitectura alternativa de tipo pipeline en cascada que consiste en una primera red neuronal encargada de localizar y recortar regiones de interés, el útero en este caso, dentro de la imagen original. Las regiones recortadas son luego procesadas por una segunda red neuronal, cuya tarea es la detección de miomas.

Para aumentar aún más el rendimiento, se incorporó una estrategia de etiquetado contextual, en la que se considera el entorno anatómico de la región de interés, lo cual mejora la precisión del modelo al reducir falsos positivos y negativos.

Finalmente, se emplearon las imágenes del conjunto de prueba para validar la concordancia de los resultados obtenidos y seleccionar el modelo con mejor rendimiento general, el cual será posteriormente considerado para su aplicación en entornos clínicos reales.

### 3.2. Criterios de inclusión y exclusión.

Se consideran como seleccionables para la conformación del conjunto de datos, imágenes de ultrasonido medico adquiridas por especialistas del área, en las que se observe la región uterina en su totalidad o de forma parcial (mínimo 60%), que a criterio visual no presenten artefactos que pudieran degradar de forma grave las características de la región de interés.

Dichas imágenes pueden haber sido adquiridas en modo Doppler color o B - 2D, siendo seleccionables siempre y cuando los artefactos o indicadores vasculares no interfieran con el objeto de interés.



# Capítulo 4.

## 4. Resultados.

### 4.1. Conformación del conjunto de datos fase 1 (Transpélvico).

Como se muestra en la figura XI, se inició el proceso con la recolección de imágenes, para ello se analizó la disponibilidad de los bancos de datos utilizados en la literatura descrita en el estado del arte del presente trabajo, de esta forma se obtuvo acceso parcial al conjunto de datos descrito en [15], consistiendo duplas imagen – etiqueta, de 871 imágenes.

<i>Dimensiones</i>	<i>Formato</i>	<i>Tipo de etiquetado</i>
1024 x 768	PNG	Polígono (shape) en archivo json

Tabla VII. características de las imágenes del banco de datos de [15] .

#### *Otras características*

Ultrasonido transabdominal
Marcas de referencia (calipers)
Presunto mioma único por imagen
Sin contexto clínico
Diversidad de casos
Clases: 0 – (tumor)

Tabla VIII. Características contextuales del conjunto 1.

#### 4.1. Preprocesamiento fase 1 (Transpélvico).

Una vez obtenidos los datos, se realizó un proceso de análisis y homologación, para clasificar y seleccionar los elementos a utilizar, de los cuales 8 elementos contaban con la modalidad Doppler color, 112 corresponden a imágenes en modo B de casos concernientes al área especializada de obstetricia, y 743 corresponden a imágenes en modo B de mujeres no embarazadas y en 8 duplas imagen – etiqueta la imagen no correspondía al área de interés o alguno de los archivos que conforman cada dupla estaba corrupto.

Se verificó la procedencia coincidente con la literatura y se tomaron como verdaderas las afirmaciones de la validación medica previa del hospital de Quanzhou. De esta forma se tomaron para la primer fase de entrenamiento 855 duplas imagen – etiqueta de ecografía en modalidad transpélvica.




Figura XII. Ejemplo de una imagen transpélvica etiquetada con mioma.

#### 4.2.División del conjunto de datos fase 1 (Transpélvico)

Una vez seleccionados los datos (imágenes congruentes con los criterios especificados) que se utilizaran para el resto del proceso, se colocaron en un directorio general, en el que con ayuda de una herramienta disponible de forma pública

(labelme2yolo), se realizó la conversión de las etiquetas al formato requerido por la red seleccionada, en este caso YOLOv8, que emplea el siguiente formato para segmentación:

*"<clase> x1 y1 x2 y2 x3 y3 ... xn yn".*

Donde:

<clase> = número entero que representa al objeto

x1 y1, x2 y2, ..., xn yn = pares de coordenadas que definen los puntos del contorno del objeto.

Una vez en el formato adecuado, se procedió a realizar la división aleatoria según el método de validación Hold-Out, obteniendo los dos subconjuntos prioritarios de entrenamiento y validación, adicionalmente se reservó un tercer subconjunto para pruebas en otras condiciones, esto siguiendo una política de 80% para el subconjunto de entrenamiento, 15% para el subconjunto de validación y 5% para el subconjunto de prueba. Para ello se utilizó el Algoritmo I, el cual hace la división de subconjuntos en forma aleatoria y conservando ambos formatos de la etiqueta para cada imagen, además de un reporte del Split que contiene la relación de archivos.

```
-----  
# INICIO
```

```
# ===== Librerías necesarias =====
```

```
import os  
import shutil  
import random  
import json  
import yaml  
from pathlib import Path  
from sklearn.model_selection import train_test_split
```

```
# ===== Configuración de rutas =====
```

```
input_dir = Path(r"directorio_del_banco_completo")  
output_dir = Path(r" directorio_del_split")  
output_dir.mkdir(parents=True, exist_ok=True)
```

```
# ===== Extensiones válidas para imágenes =====
```

```
valid_img_exts = {'.jpg', '.jpeg', '.png', '.bmp'}
```

```
# ===== Recolección de datos =====
```

```
data = []  
for file in input_dir.iterdir():  
    if file.suffix.lower() in valid_img_exts:  
        label_txt = file.with_suffix('.txt')  
        label_json = file.with_suffix('.json')  
        if label_txt.exists():  
            data.append({  
                "image": str(file.resolve()),  
                "label_txt": str(label_txt.resolve()),  
                "label_json": str(label_json.resolve()) if label_json.exists() else None  
            })
```

```

...

# ===== Recolección de datos =====
data = []
for file in input_dir.iterdir():
    if file.suffix.lower() in valid_img_exts:
        label_txt = file.with_suffix('.txt')
        label_json = file.with_suffix('.json')
        if label_txt.exists():
            data.append({
                "image": str(file.resolve()),
                "label_txt": str(label_txt.resolve()),
                "label_json": str(label_json.resolve()) if label_json.exists() else None
            })

# ===== Mezcla aleatoria del conjunto de datos =====
random.seed(42)
random.shuffle(data)

# ===== División del conjunto en entrenamiento, validación y prueba =====
train_data, temp_data = train_test_split(data, test_size=0.20, random_state=42)
val_data, test_data = train_test_split(temp_data, test_size=0.25, random_state=42)

splits = {'train': train_data, 'val': val_data, 'test': test_data}
# ===== Creación de estructura de carpetas y copiado de archivos =====
for split_name, items in splits.items():
    img_dir = output_dir / 'images' / split_name
    lbl_dir = output_dir / 'labels' / split_name
    img_dir.mkdir(parents=True, exist_ok=True)
    lbl_dir.mkdir(parents=True, exist_ok=True)

    for item in items:
        shutil.copy(item['image'], img_dir / Path(item['image']).name)
        shutil.copy(item['label_txt'], lbl_dir / Path(item['label_txt']).name)
        if item['label_json']:
            shutil.copy(item['label_json'], lbl_dir / Path(item['label_json']).name)

...

```

...

```
# ===== Generación del archivo dataset.yaml =====
yaml_path = output_dir / "dataset.yaml"
yaml_dict = {
    'train': str((output_dir / 'images/train').resolve()).replace("\\", "/"),
    'val': str((output_dir / 'images/val').resolve()).replace("\\", "/"),
    'test': str((output_dir / 'images/test').resolve()).replace("\\", "/"),
    'nc': 1,
    'names': ['utero']
}
with open(yaml_path, 'w') as f:
    yaml.dump(yaml_dict, f, sort_keys=False)

# ===== Generación del reporte del split =====
split_report_path = output_dir / "split_report.json"
with open(split_report_path, 'w') as f:
    json.dump(splits, f, indent=2)

# ===== Mensajes finales =====
print("Split completado.")
print(f"YAML: {yaml_path}")
print(f"Reporte JSON: {split_report_path}")

# FIN
```

*Algoritmo 1. Split de datos Hold-Out.*

### 4.3. Entrenamiento de la red fase 1 (Transpélvico).

Como primer acercamiento a la red neuronal convolucional en su versión 8, en conjunto con el software disponible, RTX 4060 laptop 8GB, 16GB RAM, se propusieron experimentos con configuraciones menores para evaluar el desempeño general, aquellos realizados con éxito y de relevancia se encuentran en la Tabla IX.

ID	Modelo	Épo cas	Bat ch	Pacie ncia	Optimi zador	Aum. datos	HS V_ H	HS V_S	HS V_V	Trans late	Sca le	Flip UD	Flip LR	Mo sai c	Eras ing	Crop Fraction
A-1	yolov8n-seg.pt	300	8	100	auto	Sí	0.01 5	0.7	0.4	0.1	0.5	0.0	0.5	1.0	0.4	1.0
A-2	yolov8n-seg.pt	100	16	100	auto	No	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0
B-1	yolov8s-seg.pt	100	8	100	auto	Sí	0.01 5	0.7	0.4	0.1	0.5	0.0	0.5	1.0	0.4	1.0
B-2	yolov8s-seg.pt	100	16	100	auto	Sí	0.01 5	0.7	0.4	0.1	0.5	0.0	0.5	1.0	0.4	1.0
C-1	yolov8m-seg.pt	50	8	100	auto	Sí	0.01 5	0.7	0.4	0.1	0.5	0.0	0.5	1.0	0.4	1.0
C-2	yolov8m-seg.pt	100	8	100	auto	Sí	0.01 5	0.7	0.4	0.1	0.5	0.0	0.5	1.0	0.4	1.0
D-1	yolov8s-seg.pt	100	8	100	Adam	No	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0

Tabla IX. Configuraciones iniciales propuestas conjunto 1.

Las variaciones de configuración se realizaron principalmente en el tamaño de la red, el número de épocas y en el batch, así como en el aumento de datos que la red seleccionada maneja de forma interna para el conjunto de entrenamiento, la política principal fue activar o desactivar dicho aumento, y evaluar rendimiento general incluido el tiempo.

La segunda tanda propuesta consiste en variaciones de dos propuestas personalizadas de aumento de datos y la evaluación de optimizadores disponibles como se observa en la Tabla X.

ID	Modelo	Épo cas	Bat ch	Pacie ncia	Optimi zador	Aum. datos	HS V_ H	HS V_S	HS V_V	Trans late	Sca le	Flip UD	Flip LR	Mo sai c	Eras ing	Crop Fraction
E-1	yolov8n-seg.pt	100	8	100	auto	No	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0
E-2	yolov8n-seg.pt	100	8	100	auto	Sí	0.0 15	0.7	0.4	0.1	0.5	0.0	0.5	1.0	0.4	1.0
F-1	yolov8n-seg.pt	100	16	100	Adam	Sí	0.0	0.3	0.0	0.0	0.0	0.0	0.5	1.0	0.2	1.0
F-2	yolov8n-seg.pt	100	16	100	AdamW	Sí	0.0	0.3	0.0	0.0	0.0	0.0	0.5	1.0	0.2	1.0
G-1	yolov8n-seg.pt	200	16	15	Adam	Sí	0.0	0.3	0.0	0.0	0.0	0.0	0.5	1.0	0.2	1.0
G-2	yolov8n-seg.pt	200	16	15	Adam	Sí	0.0	0.3	0.0	0.0	0.0	0.5	0.5	0.0	0.0	0.6
H-1	yolov8n-seg.pt	200	16	15	AdamW	Sí	0.0	0.3	0.0	0.0	0.0	0.0	0.5	1.0	0.2	1.0
H-2	yolov8n-seg.pt	200	16	15	AdamW	Sí	0.0	0.3	0.0	0.0	0.0	0.5	0.5	0.0	0.0	0.6

Tabla X. Configuraciones secundarias de entrenamiento conjunto 1.

#### 4.4. Entrenamiento y validación de la red fase 1 (Transpélvico).

Los resultados de dichos experimentos se muestran a continuación en la tabla X.

ID	Mejor época	Precisión	Recall	F1
A-1	226/300	1.00	1.00	1.0
A-2	49/100	1.00	0.9747	0.9872
B-1	83/100	1.00	0.9998	0.9999
B-2	79/100	1.00	0.9994	0.9997
C-1	46/50	0.9998	0.9922	0.9960
C-2	85/100	1.00	0.9999	0.9999 6
D-1	15/100	0.9919	0.9519	0.9715
E-1	28/100	0.9948	0.9609	0.9776
E-2	82/100	1.00	0.9921	0.9960
F-1	64/100	0.9917	0.9922	0.9920
F-2	88/100	0.9921	0.9841	0.9881
G-1	62/200	0.9921	0.9833	0.9877
G-2	42/200	0.9980	0.9609	0.9791
H-1	62/200	1.00	0.9824	0.9911
H-2	69/200	0.9975	0.9609	0.9789

Tabla XI. Resumen de resultados de experimentos conjunto 1.



Los mejores resultados se obtuvieron en el experimento C-2 con una precisión del 100%, Recall de 99.99% y un F1-Score de 99.99%. A continuación, se muestran las gráficas de las métricas correspondientes.




Figura XIII. Métricas de precisión y Recall experimento C-2, conjunto 1.

Al observar la matriz de confusión, podemos observar que no ocurrieron falsos positivos ni falsos negativos en el conjunto de validación.

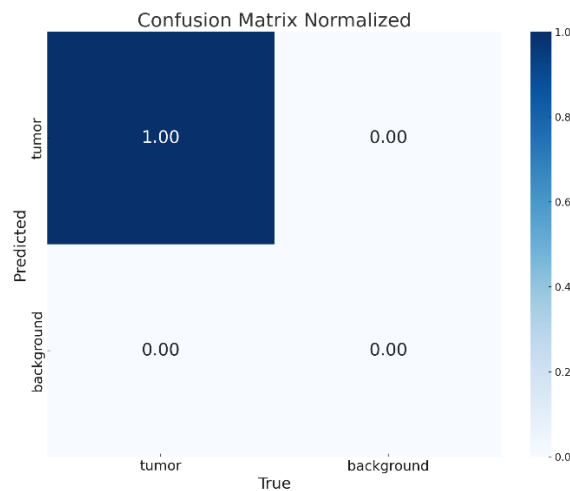


Figura XIV. Matriz de confusión experimento C-2




Figura XV. Grafica Recall - Confidence experimento C-2 conjunto 1.

Como se puede observar en la figura XV, las inferencias en el conjunto de prueba son satisfactorias y consistentes con los resultados reflejados en las figuras XIV.




Figura XVI Ejemplos de inferencia experimento C-2 conjunto 1.

Sin embargo, si tomamos en cuenta la eficiencia del modelo durante el proceso de entrenamiento, al ser una red más profunda, si bien procesa más a fondo las características del objeto de interés, podría resultar una sobremedida, ya que si observamos el experimento F-1, los resultados son similares, sin embargo, el tiempo de entrenamiento del experimento C-2 fue de 0.72 horas mientras que el experimento F-1 solo tardo 0.23 horas, aunque si bien, presento 2 falsos positivos y 3 falsos negativos como se observa en la figura X, está a criterio del especialista, evaluar cuál de los dos es más apto para el objetivo.




Figura XVII. Matriz experimental experimento F-1 conjunto 1.

#### 4.5. Conformación del conjunto de datos fase 2 (Endocavitario).

En conjunto con la especialista médica, se recopilaban imágenes de ultrasonido endocavitario del archivo personal del mismo, se exportaron directamente de los equipos de ultrasonido permitiendo así la anonimidad de las pacientes y mantener la calidad de origen en las imágenes. La recolección se realizó en 7 tandas, en las cuales las imágenes fueron brindadas al alumno para los procesos posteriores. Al final de las 7 tandas, como se muestra en la tabla XII.

<b>Tanda</b>	<b>Total de imágenes</b>
<b>1</b>	648
<b>2</b>	721
<b>3</b>	1884
<b>4</b>	247
<b>5</b>	51
<b>6</b>	62
<b>7</b>	283
<b>Total</b>	3896

*Tabla XII. Resumen de recolección de imágenes nacionales.*

#### 4.6. Preprocesamiento y división de los datos fase 2 (Endocavitario).

Se llevó a cabo un proceso de homologación y depuración, descartando aquellas imágenes que no cumplieran con los criterios técnicos o médicos establecidos. Esta etapa permitió la conformación de un subconjunto útil para el entrenamiento del modelo, dividido en imágenes con miomas y sin miomas. El protocolo seguido fue el expresado en la metodología general, ya que las imágenes no contenían etiqueta, el tesista (autor) recibió capacitación para identificar los miomas presentes en las imágenes, una vez analizadas, etiquetadas y registradas se realizaron reuniones con la médica especialista en las que se verificaba la veracidad de las etiquetas y se realizaron las correcciones pertinentes.

De las primeras cuatro tandas de recolección, se seleccionaron solamente **180** imágenes en las que se podía observar el mioma. Mas adelante se realizaron ajustes en la metodología y se seleccionaron y etiquetaron también **368** imágenes en las que se podía

observar el útero. Posteriormente, el conjunto de imágenes con mioma de las 7 tandas fue de **465** con mioma presente y etiquetado el cual fue dividido con el mismo método de validación procesado por el algoritmo 1, correspondiente a Hold-Out.




Figura XVIII. Ejemplo de imagen endocavitaria etiquetada con mioma.

#### 4.7. Entrenamiento y validación de la red fase 2 (Endocavitario).

Se replicaron los experimentos de la tabla IX como evaluación inicial para el conjunto de 465 imágenes con mioma, a lo cual se obtuvieron resultados poco favorables, tanto la precisión (m) como el recall (m) se mantuvieron por debajo de los niveles esperados, como puede observarse en la figura XV y XVI donde las curvas muestran valores modestos y poco estables entre ejecuciones.




Figura XIX. Graficas de Precisión y Recall de experimento A-2 conjunto 2.

Posteriormente se procedió entrenar el pipeline en cascada, para ello se tomaron las 368 imágenes en las que se había etiquetado útero y se agregaron las 180 en las que se encontraba mioma pero solo se etiquetó la clase útero entrenando un total de 548 imágenes a las que se les realizó Hold-Out para cada caso. Los resultados fueron los mostrados en la figura XVI y XVII.




Figura XX. Graficas de Precisión y Recall de experimento G-1 conjunto útero pipeline en cascada.





Figura XXI. Matriz de confusión de experimento G-1 conjunto útero pipeline en cascada.

Se evaluó lo aprendido por la red y se realizó la evaluación con la imágenes de prueba obteniendo una confianza consistente cercana al 90%. En la figura XVIII podemos observar dos ejemplos de este resultado con los cuales se procedió a entrenar la segunda etapa.



*Figura XXII. Recortes de útero obtenido de etapa 1 pipeline en cascada.*

Los resultados utilizados se obtuvieron mediante la configuración de 100 épocas en el modelo yolov8n-seg, con una paciencia de 20, y un batch de 8.

Los recortes fueron realizados tomando como referencia las etiquetas previas del mioma, asegurándose de que el útero estuviera completamente contenido dentro del nuevo campo visual generando así una versión alternativa del conjunto de datos, más enfocada y de menor resolución, pero más rica en información clínica relevante para la tarea de detección.

De esta forma se procedió con la siguiente etapa en la que se tomó el dataset completo de la etapa uno pero aquellas imágenes en las que no se encontraba algún mioma, mantuvieron sus etiquetas vacías para generar una diferenciación presentando a la red casos en los que solamente hay fondo y casos en los que hay fondo y miomas.

Partiendo del comportamiento de la red durante la etapa 1 y los resultados del resto de experimentos iniciales, se configuró este entrenamiento en 100 épocas con un batch de 4 y un tamaño de imagen de 512 para el modelo yolov8l-seg.

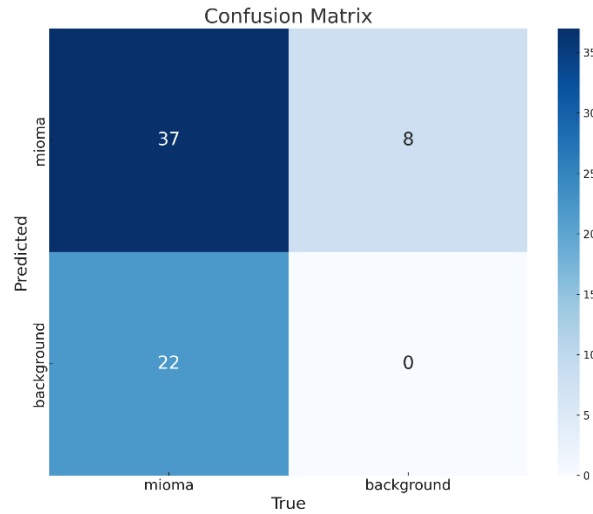


Figura XXIII. Matriz de confusión experimento con etiquetas vacías segunda etapa pipeline en cascada.

Los resultados de este experimento parecen tener potencial sin embargo aún no es apto para las pruebas médicas. En la figura XXIII podemos observar que presenta una cantidad considerable de falsos negativos y una cantidad moderada de falsos positivos, aunado a ello el Recall se mantiene bajo aunque en incremento.





Figura XXIV. Graficas de experimento con etiquetas vacías segunda etapa pipeline en cascada.



Siguiendo lo establecido en la metodología se procedió a realizar experimentos con etiquetado contextual, en los cuales se volvió a etiquetar el útero que en todos los casos es el fondo de la detección de mioma, y la región de entrada de la sonda con la que se realiza el estudio. Una vez etiquetado se procedió a iterar nuevamente el entrenamiento.



*Figura XXV. Ejemplo de imagen de etapa dos de pipeline en cascada con etiquetado contextual.*

Los resultados generales en las métricas de lo aprendido por la red mejoraron considerablemente en lo general como puede observarse en la figura XXVI.

Pese a la mejora global observada en la Figura XXVI, para mioma la asertividad continúa por debajo del criterio pre-especificado ( $\text{recall} \geq 0.90$ ,  $\text{precisión} \geq 0.80-0.85$ ): a partir de la Figura XXVII se obtiene  $\text{TP}=37$ ,  $\text{FP}=14$ ,  $\text{FN}=22$ ,  $\text{TN}=95$ , con  $\text{precisión}=0.73$ ,  $\text{recall}=0.63$  y  $\text{FNR}=37.3\%$  (elevada) y  $\text{FPR}=12.8\%$  (moderada). En consecuencia, el sistema omite ~4 de cada 10 miomas verdaderos, lo que explica la persistencia de una “proporción elevada” de errores en esta clase.




Figura XXVI. Gráficas de precisión & Recall de etapa dos de pipeline en cascada con etiquetado contextual.




Figura XXVII. Matriz de confusión de etapa dos de pipeline en cascada con etiquetado contextual.

# Capítulo 5.

## 5. Discusión de resultados

A lo largo del desarrollo de la presente tesis, se evaluó e implementó un modelo YOLO para la detección y segmentación de fibromas uterinos en ecografías. Se exploraron distintos hiperparámetros y se incorporaron técnicas de preprocesamiento/aumentación externas a la red.

El sistema propuesto para la detección de fibromas uterinos, mostró mejor desempeño en imágenes transpélvicas, alcanzando una precisión cercana al 100% en los conjuntos de validación y prueba. En contraste, el rendimiento en imágenes endocavitarias fue inferior; una causa probable es el desbalance de tamaños muestrales entre los dos subconjuntos (proporción relativa  $\approx 1.8$ ) y un cambio de dominio (diferencias en ángulo, textura y condiciones de adquisición). Esto sugiere la necesidad de ampliar el conjunto endocavitario, balancear los datos y aplicar aumentos específicos por dominio o fine-tuning estratificado. Asimismo, conviene reportar métricas complementarias (p. ej., IoU/Dice para segmentación y intervalos de confianza de precisión/sensibilidad) a fin de contextualizar valores altos y descartar sobreajuste.

# Capítulo 6.

## 6. Conclusiones

- Se implementó y evaluó un modelo YOLO para detección/segmentación de fibromas uterinos en ecografías.
- En el subconjunto transpélvico se obtuvo desempeño alto (precisión de hasta 100 % en validación y 99 % en prueba); en el endocavitario, el rendimiento fue menor.
- La asimetría de datos ( $\approx 1.8$ ) y el cambio de dominio aparecen como factores determinantes.
- Trabajo futuro: ampliar el conjunto de datos endocavitario, aplicar balanceo y aumentaciones específicas, evaluar IoU/Dice y validar con protocolos multicéntricos.

# Referencias

- [1] E. A. Stewart, «Uterine fibroids,» *The Lancet*, vol. 357, p. 293–298, 2001.
- [2] Q. Yang, M. Ciebiera, M. V. Bariani, M. Ali, H. Elkafas, T. G. Boyer y A. Al-Hendy, «Comprehensive Review of Uterine Fibroids: Developmental Origin, Pathogenesis, and Treatment,» *Endocrine Reviews*, vol. 43, pp. 678-719, November 2021.
- [3] Y. Dai, H. Chen, J. Yu, J. Cai, B. Lu, M. Dai y L. Zhu, «Global and regional trends in the incidence and prevalence of uterine fibroids and attributable risk factors at the national level from 2010 to 2019: A worldwide database study,» *Chinese Medical Journal*, p. 10–1097, 2024.
- [4] A. Al-Hendy, E. R. Myers y E. Stewart, «Uterine fibroids: burden and unmet medical need,» de *Seminars in reproductive medicine*, 2017.
- [5] S. M. Drayer y W. H. Catherino, «Prevalence, morbidity, and current medical management of uterine leiomyomas,» *International Journal of Gynecology & Obstetrics*, vol. 131, pp. 117-122, 2015.
- [6] D. D. Baird, D. B. Dunson, M. C. Hill, D. Cousins y J. M. Schectman, «High cumulative incidence of uterine leiomyoma in black and white women: Ultrasound evidence,» *American Journal of Obstetrics and Gynecology*, vol. 188, pp. 100-107, 2003.
- [7] L. A. Wise y S. K. Laughlin-Tommaso, «Epidemiology of uterine fibroids—from menarche to menopause,» *Clinical obstetrics and gynecology*, vol. 59, p. 2, 2016.
- [8] E. A. Pritts, W. H. Parker y D. L. Olive, «Fibroids and infertility: an updated systematic review of the evidence,» *Fertility and Sterility*, vol. 91, pp. 1215-1223, 2009.
- [9] M. K. Whiteman, E. Kuklina, D. J. Jamieson, S. D. Hillis y P. A. Marchbanks, «Inpatient hospitalization for gynecologic disorders in the United States,» *American Journal of Obstetrics and Gynecology*, vol. 202, pp. 541.e1-541.e6, 2010.

- [10] G. F. Jacobson, R. E. Shaber, M. A. Armstrong y Y.-Y. Hung, «Hysterectomy rates for benign indications,» *Obstetrics & Gynecology*, vol. 107, p. 1278–1283, 2006.
- [11] J. P. Hollman-Montiel y G. R. Aguiñiga, «Complicaciones de la histerectomía total abdominal ginecológica por patología benigna,» *Archivos de investigación materno infantil*, vol. 6, p. 25–30, 2014.
- [12] B. McLucas, «Diagnosis, imaging and anatomical classification of uterine fibroids,» *Best practice & research Clinical obstetrics & gynaecology*, vol. 22, p. 627–642, 2008.
- [13] Á. Huete, J. Craig, M. C. Vial, M. Fariás, H. Tsunekawa y M. Cuello, «Rol de la imagenología en el proceso diagnóstico de la patología ginecológica benigna,» *Rev Chil Obstet Ginecol*, vol. 81, p. 63–85, 2016.
- [14] D. K. T. y J. D., «Novel image enhancement approaches for despeckling in ultrasound images for fibroid detection in human uterus,» *Open Computer Science*, vol. 11, pp. 399–410, August 2021.
- [15] P. Cai, T. Yang, Q. Xie, P. Liu y P. Li, «A lightweight hybrid model for the automatic recognition of uterine fibroid ultrasound images based on deep learning,» *Journal of Clinical Ultrasound*, vol. 52, p. 753–762, 2024.
- [16] K. Suzuki, «Overview of deep learning in medical imaging,» *Radiological physics and technology*, vol. 10, p. 257–273, 2017.
- [17] K. T. Dilna, J. Anitha, A. Angelopoulou, E. Kapetanios, T. Chaussalet y D. J. Hemanth, «Classification of uterine fibroids in ultrasound images using deep learning model,» de *International Conference on Computational Science*, 2022.
- [18] A. Shahzad, A. Mushtaq, A. Q. Sabeeh, Y. Y. Ghadi, Z. Mushtaq, S. Arif, M. Z. ur Rehman, M. F. Qureshi y F. Jamil, «Automated Uterine Fibroids Detection in Ultrasound Images Using Deep Convolutional Neural Networks,» *Healthcare*, vol. 11, 2023.
- [19] U. M. Health, «Anatomía del útero,» 2024. [En línea]. Available: <https://myhealth.umassmemorial.org/Spanish/RelatedItems/34%2C17114-1es>.

- [20] Lecturio, «Útero, Cuello Uterino y Trompas de Falopio: Anatomía,» 2024. [En línea]. Available: <https://www.lecturio.com/es/concepts/utero-cuello-uterino-y-trompas-de-falopio/>.
- [21] American Society for Reproductive Medicine, *Uterine Fibroids: A Guide for Patients*, 2003.
- [22] J. B. Llusíá, *El útero: fisiología y patología*, Ediciones Díaz de Santos, 1997.
- [23] C. Guyer, S. Rajesh y M. E. Connor, «Anatomy and Physiology of the Uterus,» de *Diagnostic and Operative Hysteroscopy*, M. E. Connor y T. J. Clark, Edits., Cambridge University Press, 2020, p. 6–19.
- [24] J. Abarca Ventura, «Características epidemiológicas y clínicas de la miomatosis uterina en el Hospital Regional de Ica 2018 al 2022,» 2024.
- [25] O. Fadare y A. A. Roma, *Atlas of uterine pathology*, Springer, 2019.
- [26] A. T. Khan, M. Shehmar y J. K. Gupta, «Uterine fibroids: current perspectives,» *International journal of women's health*, p. 95–114, 2014.
- [27] E. R. Cardozo, A. D. Clark, N. K. Banks, M. B. Henne, B. J. Stegmann y J. H. Segars, «The estimated annual cost of uterine leiomyomata in the United States,» *American journal of obstetrics and gynecology*, vol. 206, p. 211–e1, 2012.
- [28] J. H. Segars y A. L. Akopians, «The two health disparities of uterine fibroids,» *Fertility and sterility*, vol. 99, p. 1851–1852, 2013.
- [29] E. Y. Soto-Velá, A. J. Jaramillo-Cañ, S. N. Aponte-Paris, G. V. Martí, I. S. Guinan, G. A. Rivera-Maldonado, A. Novas, P. L. Cruz-Rosa, I. Flores-Caldera, M. Coló y others, «Clinical and Demographic Profile of Women with Uterine Fibroids Living in Puerto Rico,» *Open Journal of Obstetrics and Gynecology*, vol. 14, p. 1347–1362, 2024.
- [30] S. D. Mitro, W. Dyer, C. Lee, A. Bindra, L. Wang, M. R. Weintraub, M. M. Hedderson y E. Zaritsky, «Uterine Fibroid Diagnosis by Race and Ethnicity in an Integrated Health Care System,» *JAMA Network Open*, vol. 8, p. e255235–e255235, 2025.

- [31] E. E. Marsh, G. E. Ekpo, E. R. Cardozo, M. Brocks, T. Dune y L. S. Cohen, «Racial differences in fibroid prevalence and ultrasound findings in asymptomatic young women (18–30 years old): a pilot study,» *Fertility and Sterility*, vol. 99, pp. 1951-1957, 2013.
- [32] E. A. Stewart, C. L. Cookson, R. A. Gandolfo y R. Schulze-Rath, «Epidemiology of uterine fibroids: a systematic review,» *BJOG: An International Journal of Obstetrics & Gynaecology*, vol. 124, p. 1501–1512, 2017.
- [33] E. Giuliani, S. As-Sanie y E. E. Marsh, «Epidemiology and management of uterine fibroids,» *International Journal of Gynecology & Obstetrics*, vol. 149, p. 3–9, 2020.
- [34] A. Ahmad, M. Kumar, N. R. Bhoi, Badruddeen, J. Akhtar, M. I. Khan, M. Ajmal y M. Ahmad, «Diagnosis and management of uterine fibroids: current trends and future strategies,» *Journal of Basic and Clinical Physiology and Pharmacology*, vol. 34, p. 291–310, 2023.
- [35] C. L. Walker y E. A. Stewart, «Uterine Fibroids: The Elephant in the Room,» *Science*, vol. 308, p. 1589–1592, June 2005.
- [36] A. P. Wickham, Y. Hewings-Martin, F. G. B. Goddard, A. K. Rodgers, A. C. Cunningham, C. Prentice, O. Wilks, Y. C. Kaplan, A. Marhol, A. Meczner y others, «Exploring Self-Reported Symptoms for Developing and Evaluating Digital Symptom Checkers for Polycystic Ovarian Syndrome, Endometriosis, and Uterine Fibroids: Exploratory Survey Study,» *JMIR Formative Research*, vol. 8, p. e65469, 2024.
- [37] S. D. Mitro, L. A. Wise, L. E. Waetjen, C. Lee, E. Zaritsky, S. D. Harlow, D. H. Solomon, R. C. Thurston, S. R. El Khoudary, N. Santoro y M. M. Hedderson, «Hypertension, Cardiovascular Risk Factors, and Uterine Fibroid Diagnosis in Midlife,» *JAMA Network Open*, vol. 7, p. e246832, April 2024.
- [38] E. Mension, F. Carmona, S. Vannuccini y C. Chapron, «Clinical signs and diagnosis of fibroids from adolescence to menopause,» *Fertility and Sterility*, vol. 122, pp. 12-19, 2024.



- [39] M. Dueholm, E. Lundorf, E. S. Hansen, S. Ledertoug y F. Olesen, «Accuracy of magnetic resonance imaging and transvaginal ultrasonography in the diagnosis, mapping, and measurement of uterine myomas,» *American Journal of Obstetrics and Gynecology*, vol. 186, pp. 409-415, 2002.
- [40] K. Koga, M. Fukui, M. Fujisawa y Y. Suzukamo, «Impact of diagnosis and treatment of uterine fibroids on quality of life and labor productivity: the Japanese online survey for uterine fibroids and quality of life (JOYFUL survey),» *Journal of Obstetrics and Gynaecology Research*, vol. 49, p. 2528–2537, 2023.
- [41] S. Sankaran y I. T. Manyonda, «Medical management of fibroids,» *Best Practice & Research Clinical Obstetrics & Gynaecology*, vol. 22, pp. 655-676, 2008.
- [42] J. Micić, M. Macura, M. Andjić, K. Ivanović, J. Dotlić, D. D. Micić, V. Arsenijević, J. Stojnić, J. Bila, S. Babić, U. Šljivančanin, D. M. Stanišić y M. Dokić, «Currently Available Treatment Modalities for Uterine Fibroids,» *Medicina*, vol. 60, 2024.
- [43] K. T. Dilna y D. Jude Hemanth, «Fibroid Segmentation in Ultrasound Uterus Images Using Wavelet Filter and Active Contour Model,» de *Data Analytics and Management: Proceedings of ICDAM*, 2021.
- [44] J. Saranya y S. Malarkhodi, «Filtering and segmentation of a uterine fibroid with an ultrasound images,» de *International Conference on Pattern Recognition, Informatics and Medical Engineering (PRIME-2012)*, 2012.
- [45] S. K. Harlapur y R. S. Hegadi, «Segmentation and analysis of fibroid from ultrasound images,» *Int. J. Comput. Appl.*, vol. 975, p. 8887, 2015.
- [46] L. Rouhiainen, «Inteligencia artificial,» *Madrid: Alienta Editorial*, p. 20–21, 2018.
- [47] P. H. Winston, *Artificial intelligence*, Addison-Wesley Longman Publishing Co., Inc., 1992.
- [48] K. Sharifani y M. Amini, «Machine Learning and Deep Learning: A Review of Methods and Applications,» *World Information Technology and Engineering Journal*, vol. 10, 2023.

- [49] Z. Sadeghi, R. Alizadehsani, M. A. CIFCI, S. Kausar, R. Rehman, P. Mahanta, P. K. Bora, A. Almasri, R. S. Alkhawaldeh, S. Hussain, B. Alatas, A. Shoeibi, H. Moosaei, M. Hladík, S. Nahavandi y P. M. Pardalos, «A review of Explainable Artificial Intelligence in healthcare,» *Computers and Electrical Engineering*, vol. 118, p. 109370, 2024.
- [50] S. Suganyadevi, V. Seethalakshmi y K. Balasamy, «A review on deep learning in medical image analysis,» *International Journal of Multimedia Information Retrieval*, vol. 11, p. 19–38, 2022.
- [51] J. Wang, H. Zhu, S.-H. Wang y Y.-D. Zhang, «A review of deep learning on medical image analysis,» *Mobile Networks and Applications*, vol. 26, p. 351–380, 2021.
- [52] F. A. Cosío, F. T. Robles, G. A. R. Velásquez-Rodríguez, E. G. Gómez, B. Escalante-Ramirez, J. Olveres, J. L. Pérez, V. M. Bañuelos, L. C. Marín y M. G. Huerta, «APRENDIZAJE COMPUTACIONAL PARA ANÁLISIS DE IMÁGENES DE ULTRASONIDO MÉDICO,» *Tecnología e Innovación en Educación Superior*.
- [53] D. K. Girija y M. S. Shashidhara, «Data mining techniques used for uterus fibroid diagnosis and prognosis,» de *2013 International Mutli-Conference on Automation, Computing, Communication, Control and Compressed Sensing (iMac4s)*, 2013.
- [54] P. Tanos, I. Yiangou, G. Prokopiou, A. Kakas y V. Tanos, «Gynaecological Artificial Intelligence Diagnostics (GAID) GAID and Its Performance as a Tool for the Specialist Doctor,» *Healthcare*, vol. 12, 2024.
- [55] R. Szeliski, *Computer vision: algorithms and applications*, Springer Nature, 2022.
- [56] W. Rawat y Z. Wang, «Deep Convolutional Neural Networks for Image Classification: A Comprehensive Review,» *Neural Networks*, vol. 61, p. 85–117, 2017.
- [57] N. Ketkar y J. Moolayil, «Convolutional Neural Networks,» de *Deep Learning with Python*, 2 ed., Apress, 2021, p. 101–134.
- [58] K. O'Shea y R. Nash, *An Introduction to Convolutional Neural Networks*, 2015.

- [59] K. Campbell, M. N. Thygeson, J. Srivastava y S. Speedie, «Exploration of Classification Techniques as a Treatment Decision Support Tool for Patients with Uterine Fibroids,» 2010.
- [60] D. V. Sumathy, D. S. J. Rexline y M. T. D. Gowri, «Decision Support Tool for Uterine Fibroids Treatment with Machine Learning Algorithms – A Study,» *International Journal of Scientific and Research Publications (IJSRP)*, 2022.
- [61] S. Prabakar, K. Porkumaran y J. Guna Sundari, «Uterine fibroid segmentation and measurement based on morphological functions in graphical vision assistant tool,» de *Emerging Research in Electronics, Computer Science and Technology: Proceedings of International Conference, ICERECT 2012*, 2014.
- [62] Y. S. Poonia, R. K. Sunkaria, D. Mittal y D. K. Patidar, «A Novel Hybrid Method for Segmentation of Ultrasound Images,» de *Proceedings of the International Conference on Recent Cognizance in Wireless Communication & Image Processing: ICRCWIP-2014*, 2016.
- [63] C. Carvalho, S. Marques, C. Peixoto, D. Pignatelli, J. Beires, J. Silva y A. Campilho, «Deep Learning Approaches for Gynaecological Ultrasound Image Segmentation: A Radio-Frequency vs B-mode Comparison,» de *Image Analysis and Recognition: 16th International Conference, ICIAR 2019, Waterloo, ON, Canada, August 27–29, 2019, Proceedings, Part II 16*, 2019.
- [64] Z. Ahmed, M. Kareem, H. Khan, Z. Saman y F. Hassan Jaskani, «Detection of Uterine Fibroids in Medical Images Using Deep Neural Networks,» *EAI Endorsed Trans. Energy Web*, vol. 1, p. 13, 2022.
- [65] T. Huo, L. Li, X. Chen, Z. Wang, X. Zhang, S. Liu, J. Huang, J. Zhang, Q. Yang, W. Wu y others, «Artificial intelligence-aided method to detect uterine fibroids in ultrasound images: A retrospective study,» *Scientific Reports*, vol. 13, p. 3714, 2023.
- [66] R. Borrego y R. González Cortés, «Fundamentos básicos de ecografía,» Madrid, España, 2020.
- [67] H. J. Farez Solano, *Importancia de la ecografía como método diagnóstico de los miomas uterinos en mujeres fértiles y menopáusicas*, Machala, Ecuador, 2019.

- [68] J. M. Ferreira Neto, L. E. O. Figueira, A. H. O. Prado, J. L. Rolim y G. A. Godinho, «Uso de técnicas de imagen en la evaluación de miomas uterinos: avances en tomografía y resonancia magnética,» *Revista Ibero-Americana de Humanidades, Ciências e Educação*, vol. 10, p. 530–532, 2024.
- [69] A. R. M. Gomes, «Sarcomatização de Miomas Uterinos,» Coimbra, 2022.
- [70] S. Lizana G, S. Aguilera Peña, L. Quiroz Villavicencio, L. Zúñiga Ibaceta y J. G. Rodríguez Aris, *Seminario 89: Ecografía ginecológica*, 2020.
- [71] B. F. Silvestrini, M. O. Rodrigues, P. D. Maia, A. R. Botelho y J. G. Mattar, «Miomas uterinos: a incessante busca pela melhor técnica cirúrgica,» *Revista Ibero-Americana de Humanidades, Ciências e Educação*, vol. 10, p. 2926–2928, 2024.
- [72] H. Xi y W. Wang, «Deep learning based uterine fibroid detection in ultrasound images,» *BMC Medical Imaging*, vol. 24, p. 218, 2024.
- [73] H. Pan, M. Zhang, W. Bai, B. Li, H. Wang, H. Geng, X. Zhao, D. Zhang, Y. Li y M. Chen, «An Instance Segmentation Model Based on Deep Learning for Intelligent Diagnosis of Uterine Myomas in MRI,» *Diagnostics*, vol. 13, 2023.
- [74] A. Z. Dilshodovna y S. S. Azimbaevna, «DETECTION AND RECOGNITION OF FIBROIDS BY SEGMENTATION THROUGH GEOMETRIC MODELING OF DYNAMIC MEDICAL IMAGES,» *BOSHQARUV VA ETIKA QOIDALARI ONLAYN ILMIY JURNALI*, vol. 3, p. 81–88, 2023.
- [75] M. El-Khatib, O. M. Teodor, D. Popescu y L. Ichim, «Identification of Benign Tumor Masses Using Deep Learning Techniques Based on Semantic Segmentation,» de *International Work-Conference on Artificial Neural Networks*, 2023.
- [76] C. Zhang, «Deep learning-based image segmentation methods in the treatment of benign and malignant uterine tumor diseases,» 2023.
- [77] J. Zhang, Y. Liu, L. Chen, S. Ma, Y. Zhong, Z. He, C. Li, Z. Xiao, Y. Zheng y F. Lv, «DARU-Net: A dual attention residual U-Net for uterine fibroids segmentation on MRI,» *Journal of Applied Clinical Medical Physics*, vol. 24, p. e13937, 2023.

